北京航空航天大学计算机学院

硕士研究生学位论文
开题报告

论文题目：面向云边端协同的跨域分布式训练通信优化技术研究

专　　业：计算机体系结构

研究方向：分布式计算

研 究 生：李云潼

学　　号：SY2306142

指导教师：肖利民

北京航空航天大学计算机学院

2024 年 11 月 27 日

目录

1. 论文研究背景与意义.....1
1.1. 论文选题背景.....1
1.2. 研究现状概述.....7
1.2.1. 云边端计算环境中减少通信量的相关工作.....7
1.2.2. 云边端计算环境中优化集合通信策略的相关工作.....9
1.3. 研究目标与创新性.....11
1.3.1. 研究目标.....11
1.3.2. 创新性.....11
2. 研究内容与技术路线.....13
2.1. 研究内容.....14
2.1.1. 基于差分传输与模型感知的参数压缩策略.....14
2.1.2. 基于混合精度的自适应优化器方法.....14
2.1.3. 基于并行策略与网络状态感知的跨域集合通信方法.....14
2.2. 研究方案.....15
2.2.1. 基于差分传输与模型感知的参数压缩策略.....15
2.2.2. 基于混合精度的自适应优化器方法.....18
2.2.3. 基于并行策略计划与网络状态感知的跨域集合通信方法.....19
3. 论文工作安排.....21
3.1. 工作进度安排.....21
3.2. 论文工作基础.....22
3.2.1. 研究方案的具体进展.....22
3.2.2. 已录用或已投稿的论文.....23
3.2.3. 申请或参与项目情况.....23
3.3. 可能遇到的问题以及解决途径.....23

主要参考文献.....25

图目

图 1 云边端协同分布式训练技术概览.....2
图 2 论文的关键科学问题、研究内容和研究目标.....13
图 3 论文总体研究方案.....15
图 4 基于差分传输与模型感知的参数压缩策略总体方法.....16
图 5 运行时通信拓扑重生成机制.....19
图 6 集合通信动态调度机制.....20

表目

表 1 论文研究时间安排.....21

1. 论文研究背景与意义

在本节中，将会详细介绍论文的研究背景与意义，主要分论文选题背景、研究现状概述、研究目标与创新性 3 个方面进行介绍。

1.1. 论文选题背景

云边端计算环境是服务国家关键领域数智化转型的重要基础设施，支撑了电网、交通、制造等关键领域的发展，创造了全新的新质生产力，且已经成为了全球范围内的研究热点和竞争焦点。

云边端计算环境成为各个国家和地区的竞争焦点。为了应对日益增长的云边端计算环境需求，世界各国政府纷纷制定了相关的文件、计划、政策。例如，美国自 2019 年来相继发布了《国家战略性计算计划：引领未来计算》[1]、《引领未来先进计算生态系统：战略计划》[2]、《美国防部 5G 战略实施计划》[3]、《关键和新兴技术清单》[4]等关键政策性文件，引导、推动美国边缘计算、雾计算、云边端协同等相关技术的发展。在欧洲方面，欧盟委员会相继发布了“ECI 计划”[5]、“地平线计划”[6]、“欧洲共同利益重要计划”[7]等相关的科技计划，批准了多达 12 亿以上欧元的专门资金，用以推动云计算、边缘计算的发展。我国同样注重发展云边端计算环境，“党的二十大报告”、《“十四五”数字经济发展规划》、《数字中国建设整体布局规划》、《新型数据中心发展三年行动计划（2021-2023）》等政策文件都不约而同的提及了云边端计算环境，并对其发展擘画蓝图。

云边端协同技术已经得到了长足的发展和进步。云边端协同跨域计算是支撑算力基础设施实现关键领域数智化的关键技术之一，涵盖计算、存储、网络、任务等多维度。当前，云边端协同跨域计算领域发展迅速，市场上出现了许多相关的系统平台，如微软云的 Public MEC 平台[8]、亚马逊的 AWS for Edge 平台[9]、Rancher 的 Octopus[10]等，支撑了如大众智能工厂[11]、iRobot 智能服务机器人[12]、DISH 云原生网络[13]的发展，实现了高效的云边端协同。

我国在云边端协同计算领域涌现了诸多产品与工作。目前国内企业和高校推出了相关系统平台，如华为的 KubeEdge[14]、腾讯的 SuperEdge[15]、阿里的 OpenYurt[16]以及北航的跨域虚拟数据空间 GVDS[17]等。在知识产权方面，Google

Patents 显示云边端协同跨域计算相关专利已超过 2500 件，IBM、Intel、AT&T 等美国企业拥有相关专利 200 余件，国家电网、北航等国内单位在此领域拥有部分专利，但数量明显少于国外单位。

图 1 云边端协同分布式训练技术概览

智能化成为未来云边端计算环境重要的竞争方向。根据 IDC 的调研，人工智能技术带动了新一波的云边端计算环境发展浪潮，2023 年我国云边端计算市场同比增长 29.1%，预计到 2028 年，市场规模将达到 132 亿美元[18, 19]。所示，在智能化浪潮下，众多软硬件厂商共同发力提供了多种云边服务器和模型训推软件。在软件方面，Meta 联合 Arm、Apple、Qualcomm 等厂商发布了 ExecuTorch[20]将 PyTorch[21]的能力拓展到边缘，提升跨硬件设备的兼容性并降低框架开销，以实现快速的边缘推理；Apache 基金会主导开发了 TVM 引擎[22, 23]，架起了多种深度学习框架和异构硬件之间桥梁，为在多样化的嵌入式设备中运行 AI 模型推理任务提供了可能；Google 同样开发了 TensorFlow Lite[24]人工智能框架，提供了模型选择、转换、加速、优化等能力，为边端侧的模型优化、部署、推理奠定了良好的基础。在硬件方面，NVIDIA 推出了 Jetson[25]、Orin[26]等平台和芯片，成功地将智能模型拓展到边端侧，成为边缘计算智能硬件的标杆；并且，NVDIA 还推出了针对边缘计算优化的 TensorRT[27]工具包，通过与 Jetson 等平台的协同优化，以提供卓越的模型推理性能；AMD 则推出了基于 XDNA 架构的 AMD Ryzen

AI SoC[28]与 ROCm 工具包[29]，为个人 PC、边缘服务器提供强大的智能算力；国内厂商如天数智芯、寒武纪、沐曦、华为等都推出了自主研发的 GPGPU 和 NPU，为边缘侧推理提供了强大的算力。

综上，在云边端计算环境已经成为了国内外研究和竞争的焦点，并且智能化已经成为了不可阻挡的浪潮，我国需要持续发力，迎头赶上。在云边端计算环境中，已经可以通过 TVM[20, 23, 24]等软件、Jetson[25, 28]等硬件实现高效的模型推理；但是，随着边端侧硬件算力的增强、基础框架软件的发展、网络连接速度的提升，将模型训练、微调从云侧拓展到边端侧将逐步成为可能。

云边端协同的跨域分布式模型训练具有隐私性好、成本低、准确度高等优势。首先，云边端协同的跨域模型训练有利于保护敏感数据，提升隐私性；在云边端计算环境中，大部分数据来自于边端侧，这些数据通常涉及用户隐私和众多领域知识而成为敏感数据，如果遵循“端侧采集-边侧清洗-云侧训练”的模式，敏感数据将在云边端计算环境中经历多次计算、传输、存储，十分不利于用户的隐私和领域知识的保护[30]；采用跨域分布式模型训练时，模型训练可以在边端侧完成，避免了数据的多次计算、传输、存储，从而避免了敏感数据的外泄。其次，云边端协同的跨域模型训练降低了模型训练的成本；在云边端计算环境中，边端侧算力有了较大的提升，在边端侧设备中直接进行模型的训练、微调、推理成为可能；开展云边端协同的跨域分布式模型训练时，可以充分利用边端侧智能算力，同时以稀疏的模型参数传输替代稠密的训练数据传输；所以云边端协同的跨域分布式模型训练可以显著的提升云边端计算环境中可用的智能算力总量，并且降低数据传输的能源开销[31]。最后，云边端协同的跨域模型训练有利于提升模型的准确率；在云边端计算环境中，不同边端侧的数据特征分布不尽相同，例如照片中的噪点、音频中的风声等，这些干扰会显著降低模型性能；因此，在不同的边端设备中运行同一个模型时，会出现准确率下降的问题；所以，在不同的边端侧设备中，使用不同分布的数据训练、微调基础模型进行持续的学习，可以明显提升模型在不同场景下的准确率[32, 33]。

云边端协同的跨域分布式模型训练具有鲜明的环境特点和工作特征。在云边端协同的跨域分布式模型训练场景下，模型训练任务运行于动态、异构的跨域

节点中，呈现出云边端跨域智能计算硬件异构性强、云边端跨域节点之间的通信成本高、云边端跨域并行训练环境动态性强的新特征。

① 云边端跨域节点之间的通信成本高

在云计算中心进行模型的集中化训练时，数据中心通常会使用 RDMA[35, 36]、NVLink[37]、CXL[38]等高速互联手段，以提升模型的分布式训练速度。但是，在云边端协同的跨域分布式模型训练场景下，各个节点可能使用 4G、5G、Wi-Fi、以太网等无线或传统的互联方式，在通信带宽和通信延迟方面都无法与数据中心内的高速网络相提并论。具体来说，NVLink 目前的双向互联带宽为 1.8TB/s，NVLink Switch 支持 14.4TB/s 的无阻塞交换能力[37]；但是云边端计算环境中常见的万兆以太网仅能做到 10Gbit/s，约合 1.25GB/s 的互联速度[39]。

② 云边端跨域并行训练环境动态性强

在云计算中心进行模型的集中化训练时，数据中心的计算硬件、存储硬件和网络拓扑相对固定，有经验的开发人员可以很轻易的设计出高效的并行方式。但是，在云边端协同的跨域分布式训练场景下，设备间的互联带宽和节点间的互联情况都会发生改变，固定的分布式模型训练策略难以适应这种情况，需要动态地搜索可能的优化空间，并在适当时机进行并行策略的切换[40]。例如，在 3 个边节点 A、B、C 和云计算中心 F 中发起了跨域模型训练任务，此时 C 节点掉线，此时需要尽快地调整模型训练并行策略，将 C 节点的计算任务切换到其他节点中运行执行。

云边端协同的跨域分布式计算训练场景对跨域分布式计算框架的设计提出了新的挑战，如何设计新型的跨域分布式计算框架以高效满足跨域分布式训练的需求成为亟待解决的关键问题。计算框架可以实现对底层异构硬件、复杂通信过程等的屏蔽，是加速应用开发、提升计算效率的重要手段。在人工智能领域，已经涌现了众多的人工智能框架，如 PyTorch[20, 21, 41]、TensorFlow[42, 43]、PaddlePaddle[44]、MindSpore[45]、Jax[46]等。在进入大模型时代后，针对大模型训推也出现了众多的分布式计算框架，例如 DeepSpeed[47]、Megatron-LM[48, 49]、Colossal-AI[50]等；上述计算框架提供了分布式通信、分布式并行、模型压缩、推理优化等能力。这些人工智能计算框架极大的挖掘了硬件潜力，缓解了通信瓶颈，

提供了多样化的并行能力，极大的提升了在单机、计算中心内的计算效率和资源利用率。因此，可充分利用现有的计算框架研发成果，针对跨域分布式训练表现出的新特征，研发对应的跨域分布式计算框架，以充分支持云边端协同的跨域分布式训练场景。

然而，针对云边端协同场景研发一款跨域分布式计算框架，在异构计算、网络通信、并行策略生成等方面都面临着诸多亟待解决的问题。在云边端协同的跨域分布式计算场景下，模型训练任务呈现出在运行于多样化异构智算硬件、云边端不同节点之间的通信成本高和手动规划并行策略困难的新特征，在异构计算、网络通信、并行策略生成等方面给跨域分布式计算框架的设计与实现带来了全新的挑战。

① 如何实现云边端跨域高效参数通信

云边端跨域参数通信对于模型训练任务至关重要，在云边端协同的分布式计算场景中，参数通信是实现模型训练和优化的关键环节。高效的参数通信可以减少模型训练的时间，提高模型训练的效率和效果。因此，如何高效的实现云边端跨域参数通信成为云边端协同的跨域分布式计算中亟待解决的关键问题。

云边端跨域高效参数通信面临着通信带宽和延迟的挑战：由于云边端节点间通信带宽有限和延迟较高，这直接影响了模型训练过程中的数据同步和梯度更新效率。为了应对这一挑战，可以采取一些策略，比如使用梯度压缩和量化技术来减少通信量，以及设计更高效的通信协议来降低延迟。但这一般意味着采取更为激进的压缩策略。

云边端跨域高效参数通信面临着模型精度受损的挑战：在通信过程中，为了减少通信量，通常会采取量化与稀疏化的参数进行通信，但这可能会引起模型精度的损失，而在云边端场景下，更为底下的带宽将会进一步恶化由量化与稀疏化引起的精度损失。目前，已有的方法包括 ZeRO++，DGC，PowerSGD 等方法，能够有效的压缩梯度数据，但是无法在高压缩场景下仍旧保持好的模型精度。

② 如何实现云边端通信高效的优化器策略

分布式计算节点的通信速度对于模型训练任务的性能至关重要。在云边端协同的跨域分布式计算场景中，跨域节点间的通信成本较高，通信带宽和延迟都无

法和数据中心内相提并论。因此，如何高效地实现云边端跨域节点快速通信成为云边端协同的跨域分布式计算中亟待解决的关键问题。

云边端高效优化器策略面临着通信带宽和延迟的挑战。在云边端协同的分布式计算中，由于节点间通信带宽有限和延迟较高，导致模型训练过程中的数据同步和梯度更新效率低下。这种带宽和延迟的限制，尤其是在无线网络环境下，成为了优化器设计中必须考虑的重要因素。为了应对这一挑战，可以采取一些策略，比如通过优化数据传输策略来减少通信量，例如使用量化技术，以及设计更高效的通信协议来降低延迟。

云边端高效优化器策略面临着模型精度损失和收敛速度慢的挑战。量化与稀疏化的梯度通信虽然可以减少通信量，但可能会引起模型精度的损失，同时由于信息的不完整性，导致模型收敛速度变慢。为了解决这些问题，可以采用一些先进的优化技术，比如使用混合精度训练，这可以在减少内存占用的同时保持模型的精度。此外，还可以采用多粒度的选择性重计算策略，根据当前显存占用情况选取最佳的重计算策略，达到计算性能和显存占用之间的平衡。还有研究提出了基于分布式强化学习的协同流量调度算法，通过实验验证了所提协同流量调度方案的有效性，这可以为优化器策略提供参考。同时，也有研究提出了跨云边端协同计算的方法，通过任务切分和协同执行，将一个任务切分成多个子任务，并将这些子任务分配给不同的设备，最后将它们的结果合并得到最终结果，这种方法可以充分利用各节点的资源，提高处理效率。

③ 如何动态地生成云边端跨域集合通信策略

动态生成云边端跨域训练集合通信策略对于模型训练任务至关重要。在云边端协同的跨域分布式计算场景中，云边端环境动态变化，网络拓扑、连接关系、连接能力都会发生变化。因此，如何动态地生成云边端跨域集合通信策略成为云边端协同的跨域分布式计算中亟待解决的关键问题。

生成云边端跨域训练集合通信策略面临着如何设计通信拓扑策略的挑战。在云边端计算环境中，应用定制的通信拓扑进行集合通信，合理的处理不同节点间通信能力不统一，是提升跨域模型训练的有效手段。目前，现有的通信拓扑规划主要有 Tree All-Reduce、Double Binary Tree All-Reduce、Ring All-Reduce、

Hierarchical Ring All-Reduce、2D-Torus 等手段，在云边端计算环境中仍处于给出固定拓扑进行通信的固定集合通信模式。然而，由于复杂的数据分布，异构的计算设备、不稳定的互联网络，在云边端计算环境中简单的利用某一拓扑通信策略或对其进行简单的组合，并不能提升云边端环境中的通信效率；需要进行全新的设计，可以针对不同的环境动态的分层使用不同的通信拓扑策略，最大化集合通信效率。

生成云边端跨域训练集合通信策略面临着如何调度通信原语的挑战。在云边端计算环境中，通信原语是实现集合通信操作的基本单元，它们包括但不限于发送（Send），接收（Receive），广播（Broadcast）、规约（Reduce）等。这些原语的调度对于确保数据在不同节点间高效传输至关重要。目前，现有的一些调度手段有动态调度策略，使得调度器优先选择对延迟更敏感的通信任务。

综上所述，云边端计算环境是未来科技和产业竞争的制高点，发展面向云边端协同的跨域分布式技术是大势所趋。在云边端计算环境中，进行跨域分布式训练表现出不同于以往模型训练的全新的特点，例如云边端跨域智能计算硬件异构性强、云边端跨域节点之间的通信成本高、云边端跨域并行训练环境动态性强等。对跨域分布式计算框架的设计和研发提出了诸多亟待解决的全新问题。

1.2. 研究现状概述

近期，云边端计算环境的智能化技术进步带来了对跨域分布式计算框架的新挑战，尤其是在通信优化方面。在这样的环境中，模型训练任务需要在异构性强、通信成本高、动态性大的云边端跨域节点上执行。这些新挑战促使国内外学术界和工业界聚焦于如何减少通信量、优化集合通信策略等关键问题，以适应跨域分布式训练的新需求。广泛的研究工作已经在这些领域展开，旨在通过创新的通信优化技术，提升云边端计算环境中分布式训练的效率和效果。相关的文献综述如下：

1.2.1. 云边端计算环境中减少通信量的相关工作

减少通信量是指在传输之前压缩梯度或模型参数，以减小数据传输的规模，减低分布式模型训练通信开销的方法，常见的减少通信量的方法有量化和稀疏化

两种。

微软为了实现超大规模的模型训练，提出了 ZeRO 优化策略[62–64]。ZeRO 可以在多个 GPU 之间分配模型权重、梯度和优化器状态来实现并行计算，从而增加通信量和频率，但是却引入了巨量的通信开销；为了尽可能减小通信开销，微软基于 ZeRO 提出了 ZeRO++通信优化策略[65]。其采用权重量化，将模型参数在通信之前实时地压缩为更小的数据类型（INT8），从而减少了所需的通信带宽和时间；此外，ZeRO++在每台机器上维护完整的模型副本，增强机器内部的通信带宽。Wang 等人提出了一种混合压缩技术 CocktailSGD[66]。该技术结合随机稀疏化、Top-K 稀疏化和参数量化等三种不同的压缩技术，巧妙地将通信与局部梯度计算重叠，在仅有 500Mbps 的以太网中实现了卓越的训练性能。Song 等人创造性的提出了一种基于压缩的 3D 并行技术 Optimus-CC[67]。该技术在数据并行的流程压缩的基础上，实现了全新的级间反向传播压缩和嵌入同步压缩，并且研发了全新的关键通信路径识别机制；在不同训练阶段，根据通信需求动态、选择性地进行压缩，从而在尽可能维持模型精度的前提下，最大程度地减少不必要的通信开销，提升整体训练效率。Yu 等人提出了一种双重量化技术以加速模型训练过程[68]。该技术首先提出了一种同时量化模型参数和梯度的通用方案，其次基于该通用方案，提出了异步地精度并行算法、梯度稀疏-双重量化、动量量化加速技术等 3 种提升通信效率的算法。Chen 等人提出了一种可拓展的稀疏化梯度压缩策略 ScaleCom[69]。该技术利用工作节点之间梯度分布的相似性提供可交换压缩器并保持通信成本与工作节点数目一致，并且使用包含局部梯度累积的低通滤波器以减轻大批量训练的影响。Hu 等人提出了一种混合梯度压缩和梯度稀疏化的混合压缩策略 HGC[70]。该技术实现了一种动态选择策略，可以在工作节点工作的过程中动态的选择采用量化或者稀疏化策略，以结合两种方法的优点，实现较高的压缩率和较好的训练效果。

现有的减少通信量的方法一般使用量化、稀疏化等两种手段作为基本方法，得到了令人惊叹的压缩比和训练的加速比，未来将会朝着特定模型优化、特定网络条件优化的方向发展。但是，现有的减少通信量的压缩方法缺乏对低带宽、高延迟网络场景的优化。

1.2.2. 云边端计算环境中优化集合通信策略的相关工作

优化通信模式是指在节点通信时通过优化通信库拓扑结构、调度集合通信通信发起时机等方式加速模型训练节点间通信速度的方法。

Gan 等人提出了一款 Bagua 的 MPI 风格通信库[71]。Bagua 提供了一系列既灵活又模块化通信原语，以支持基于数据并行的分布式模型训练中的最先进的“system relaxations”技术，例如量化、去中心化通信和延迟通信等；通过这种设计，Bagua 实现了对各种分布式训练机制的高效支持和扩展。Duan 等人提出了一种在传输层加速模型训练的通信调度技术 Mercury[72]。Mercury 构建了一个简单的传输层调度器，将张量传输的优先级调度移动到传输层，以数据包为粒度完成调度；通过上述手段，Mercury 消除了张量传输调度的启动延时和超参数的快捷调整，加速模型训练速度。Chen 等人提出了一种全新的针对 LLM 训练的通信调度框架 Centauri[73]。该技术将混合并行训练中的调度任务分解为算子、模型层、模型三个层次，探索了由原始替换分区、拓扑感知组分区和工作负载分区组成的优化空间，构建了适合异构环境的新型通信调度框架。Fang 等人提出了一种适用于分布式训练的网络聚合路由 GRID[74]。GRID 在分布式训练中使用梯度路由与网络聚合，在控制平面上，使用基于随机舍入的高效梯度路由算法，在数据平面上，通过精心设计工作节点和可编程开关逻辑实现网内聚合，通过上述手段缓解了训练集群内的网络瓶颈。Lao 等人提出了一种适用于多租户学习的网络聚合策略 ATP[75]。ATP 使用新兴的可编程交换机支持集群中多个机架交换机的网络内聚合，以加速深度学习训练作业。ATP 采用分散、动态、尽力而为的聚合策略，能够在同时运行的深度学习训练作业之间高效、公平地共享有限的交换机资源，并妥善应对交换机资源的激烈争用。Liu 等人提出了路由聚合的网络聚合策略 InArt 加速模型训练[76]。InArt 是第一个在多 PS 架构中引入网内聚合和路由选择的工作，其采用多 PS 架构将模型训练任务拆分到多个 PS 之间，并选择合适的路由方案以充分利用网内聚合能力。Gebara 等人提出了一种用于共享集群机器学习工作负载的网络架构 PANAMA[77]。PANAMA 由一个高效的网络加速硬件和配套的拥塞控制协议组成，实现了大规模通信负载的卸载和不同流之间公

平的网络资源共享。Wang 等人面向层内并行时通过规模过大的问题，提出了一种全新的通信-计算分解技术[78]。此技术可以识别原始的通信集合与相关的计算操作，并将它们协同分解为一系列更细粒度的操作，以创造更多的重叠机会；并且此技术可以并行执行新创建的、更细粒度的通信和计算操作，从而有效地实现了计算和数据的重叠，隐藏了数据传输延迟，并实现了更好的系统利用率。Feng 等人提出了一种用于异构内存的流水线策略 Mobius[79]。该策略将模型划分规约成一个整数规划问题，以实现更细粒度的模型划分；该策略在 GPU 和 DRAM 之间进行模型划分的细粒度调度，将数据从 CPU 预取到 GPU 内存以进行下一阶段的计算，充分的实现通信和计算的重叠；此外，它还采用交叉映射策略来减少通信争用，进一步优化整体性能。Oh 等人提出了一种乱序反向传播技术 Out-Of-Order BackProp[80]。该技术针对单 GPU 训练、数据并行、流水线并行分别通过多流调度、梯度重排序、关键梯度识别三项技术，优化计算输出梯度、权重梯度和参数更新的顺序，最大化了通信和计算之间的重叠。Li 等人提出了一种全新的使用了 3D 并行的通信管到 Fold3D[81]。Fold3D 提出了用于 3D 并行的 AIAO 调度，该调度将一个深度学习模型切分成多个段，以统一调度处理同一深度学习模型的段计算任务，并且启动该段的通信任务的同步，以与其他段的计算任务重叠。Lai 等人提出了一种自动 3D 并行优化和通信技术 Merak[82]。该技术通过自动模型分区实现 3D 并行的自动部署，另外还集成了转移关键路径管道调度、空闲内存感知的重计算以实现计算和通信的重叠。Zhang 等人提出了一种内存友好的 MoE 模型流水线并行技术 MPMoE[83]。该技术可通过自适应和内存高效的流水线并行性加速 MoE 训练，并将 MoE 的训练过程分为多个独立子阶段，设计了全新的计算-通信重叠减少通信延迟。

现有的优化集合通信策略的方法一般以优化通信库、变化集合通信拓扑、优化集合通信调度为主要思路，并且取得了较好的机器学习训练加速效果，未来将继续朝着定制硬件、定制网络结构优化的方向发展。在云边端计算环境中，网络网络种类、网络拓扑多样，现有的通信拓扑优化、通信调度优化难以适用这样的场景和需求。

1.3. 研究目标与创新性

本节中，将会分研究目标和创新性 2 个方面介绍学位论文的相关内容。

1.3.1. 研究目标

本论文的研究目标是，针对模型云边端协同跨域分布式训练需求，突破基于差分传输与模型感知的参数压缩策略、基于混合精度的云边端跨域自适应优化器量化方法、基于并行策略计划与网络状态的跨域集合通信方法，建立面向云边端协同的跨域分布式训练通信优化架构，解决跨域分布式训练中云边端跨域参数通信的高效性、云边端跨域节点通信的高效性、云边端并行训练策略的动态性等科学问题，实现面向云边端协同的跨域分布式训练任务的高效执行，提升云边端资源的利用率和智能化水平。

本论文的研究目标可具体分解为：① 针对跨域分布式训练如何实现云边端跨域高效模型参数传输的问题，研究基于差分传输与模型感知的参数压缩策略，实现模型的压缩传输，减小云边端内分布式训练通信规模且将模型精度损失控制在一定范围内，提升模型跨域分布式训练速度与训练效率；② 针对跨域分布式训练如何实现云边端通信高效的优化器策略的问题，研究基于混合精度的自适应优化器方法，有效地加速云边端场景下的训练收敛性能，提升大规模分布式训练计算效率；③ 针对跨域分布式训练中如何动态地生成云边端跨域集合通信策略的问题，研究基于并行策略计划与网络状态感知的跨域集合通信方法，根据环境的动态变化，动态的生成集合通信方法，有效应对云边端计算环境的动态性。

1.3.2. 创新性

本节中将会详细描述本论文所提出的 3 种技术的创新性，具体如下：

1、基于差分传输与模型感知的参数压缩策略与现有方法相比，具有环境适配性高、压缩算法灵活度高、压缩后模型精确度高的优点。

2、基于混合精度的自适应优化器方法与现有方法相比，具有可适配带宽低、延迟高网络，计算成本低，在高压缩场景下训练收敛速度快，模型精度高的优势。

3、基于并行策略计划与网络状态感知的跨域集合通信方法与现有方法相比，具有带宽低场景下集合通信速度快、适用多种并行策略的优点。

2. 研究内容与技术路线

随着人工智能技术在云边端计算环境的广泛应用，在云边端计算环境中开展跨域分布式模型训练成为未来发展的新趋势。在云边端计算环境中，模型训练任务运行于动态、异构的跨域节点中，呈现出云边端跨域智能计算硬件异构性强、云边端跨域节点之间的通信成本高、云边端跨域并行训练环境动态性强的新特征。这对跨域分布式训练框架的设计提出了系列挑战性新问题：如何充分地利用多样云边端异构计算资源、如何高效地实现云边端跨域节点快速通信、如何动态地生成云边端跨域训练并行策略。

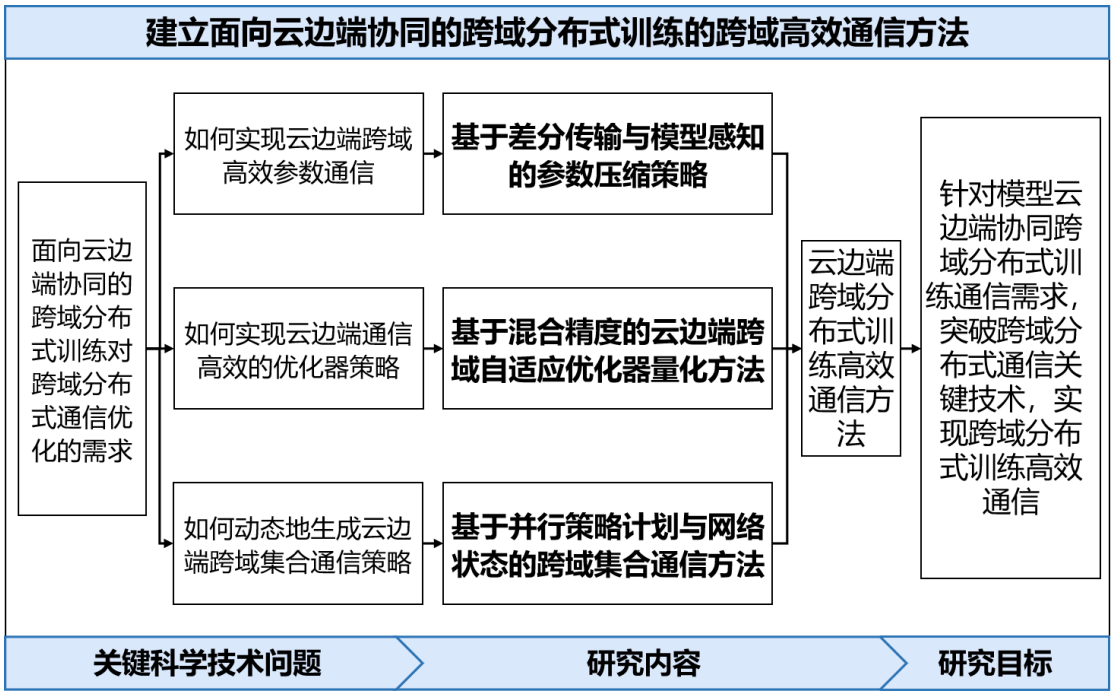

图 2 论文的关键科学问题、研究内容和研究目标

本论文的关键科学问题、研究内容、研究目标如图 2 所示。本论文以当前云边端协同的跨域分布式训练通信背后的核心需求和关键问题为导向，以高效支持面向云边端协同的跨域分布式训练任务为目的，聚焦跨域分布式训练通信优化的研究，从参数通信、优化器策略、集合通信策略 3 个方面入手，研究基于差分传输与模型感知的参数压缩策略、基于混合精度的云边端跨域自适应优化器量化方法和基于并行策略计划与网络状态感知的跨域集合通信方法。最终，构建一套云边端跨域分布式训练高效通信方法，形成跨域分布式计算通信的基本架构。

2.1. 研究内容

本论文的主要研究内容如下：

2.1.1. 基于差分传输与模型感知的参数压缩策略

针对跨域分布式训练如何实现云边端跨域高效模型参数传输的问题，研究基于差分传输与模型感知的参数压缩策略。首先进行模型参数的敏感性识别，通过在运行时捕获优化器中间值，近似计算模型参数 Hessian 矩阵，以表示模型关于模型参数的敏感度；其次进行模型参数差分数据的构建，通过在优化器更新模型时，捕获优化器模型参数更新量，从而组成差分模型；最后结合模型参数敏感性识别对捕获的模型差分参数进行压缩，通过进行量化与稀疏剪枝方法，根据参数敏感性动态压缩模型参数差分量，实现动态感知参数的模型压缩策略。通过上述机制，以实现模型的压缩传输，减小云边端内分布式训练通信规模且将模型精度损失控制在一定范围内，提升模型跨域分布式训练速度与训练效率。

2.1.2. 基于混合精度的自适应优化器方法

针对跨域分布式训练如何实现云边端通信高效的优化器策略的问题，研究基于混合精度的自适应优化器方法。首先，研究混合精度训练下的自适应优化器量化建模，通过建立量化场景下的自适应梯度下降方法，加速在压缩通信场景下模型的收敛性能；其次，研究优化器状态压缩策略，主要包含激活值、梯度与优化器中间量的压缩。通过上述机制，有效地加速云边端场景下的训练收敛性能，提升大规模分布式训练计算效率。

2.1.3. 基于并行策略与网络状态感知的跨域集合通信方法

针对跨域分布式训练中如何动态地生成云边端跨域集合通信策略的问题，研究基于并行策略计划与网络状态感知的跨域集合通信方法。首先，研究运行时集合通信拓扑动态构建方法，通过进行网络感知，结合并行策略与网络状态构建进行集合通信时节点间的通信拓扑；其次，研究运行时集合通信调度机制，通过分析并行策略，得到通信的关键路径，优先调度因通信而阻塞的进程。通过上述机制，根据环境的动态变化，动态的生成集合通信方法，有效应对云边端计算环境

的动态性。

2.2. 研究方案

面向云边端协同的跨域分布式训练，在模型参数传递、高压缩场景下优化模型、集合通信策略等方面都面临着诸多亟待解决的问题。在云边端协同的跨域分布式计算场景下，模型训练任务呈现出云边端不同节点之间的通信成本高，带宽波动大的新特征，在模型参数传递、模型训练效率、集合通信策略等方面给跨域分布式训练通信的设计与实现带来了全新的挑战。

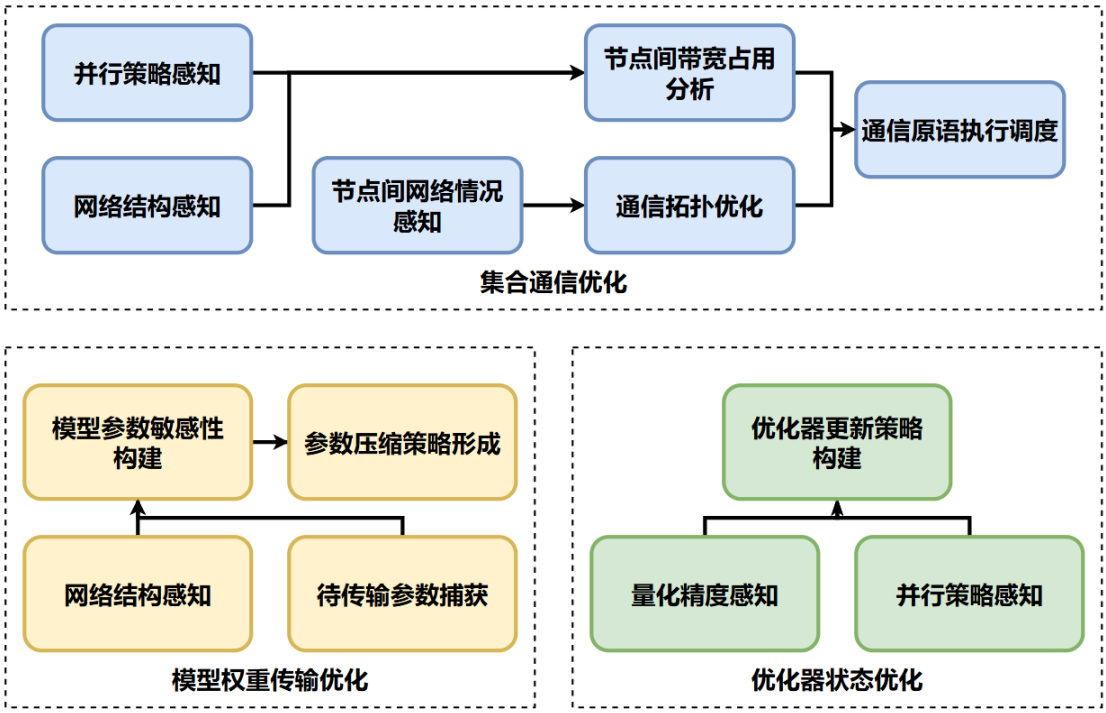

图 3 论文总体研究方案

如图 3 所示，显示了本论文的总体研究方案。具体来说，针对实现云边端跨域高效模型参数、如何实现云边端通信高效的优化器策略、如何动态地生成云边端跨域集合通信策略等关键科学问题，分别研究基于差分传输与模型感知的参数压缩策略、基于混合精度的自适应优化器方法、基于并行策略与网络状态感知的跨域集合通信方法，最终形成面向云边端协同的跨域分布式通信优化方法。

2.2.1. 基于差分传输与模型感知的参数压缩策略

针对上述两个挑战，拟提出一种基于差分传输与模型感知的参数压缩策略。首先，本方法进行模型参数的敏感性识别，通过在运行时捕获优化器中间值，近

似计算模型参数 Hessian 矩阵，以表示模型关于模型参数的敏感度；其次进行模型参数差分数据的构建，通过在优化器更新模型时，捕获优化器模型参数更新量，从而组成差分模型；最后结合模型参数敏感性识别对捕获的模型差分参数进行压缩，通过进行量化与稀疏剪枝方法，根据参数敏感性动态压缩模型参数差分量，实现动态感知参数的模型压缩策略。

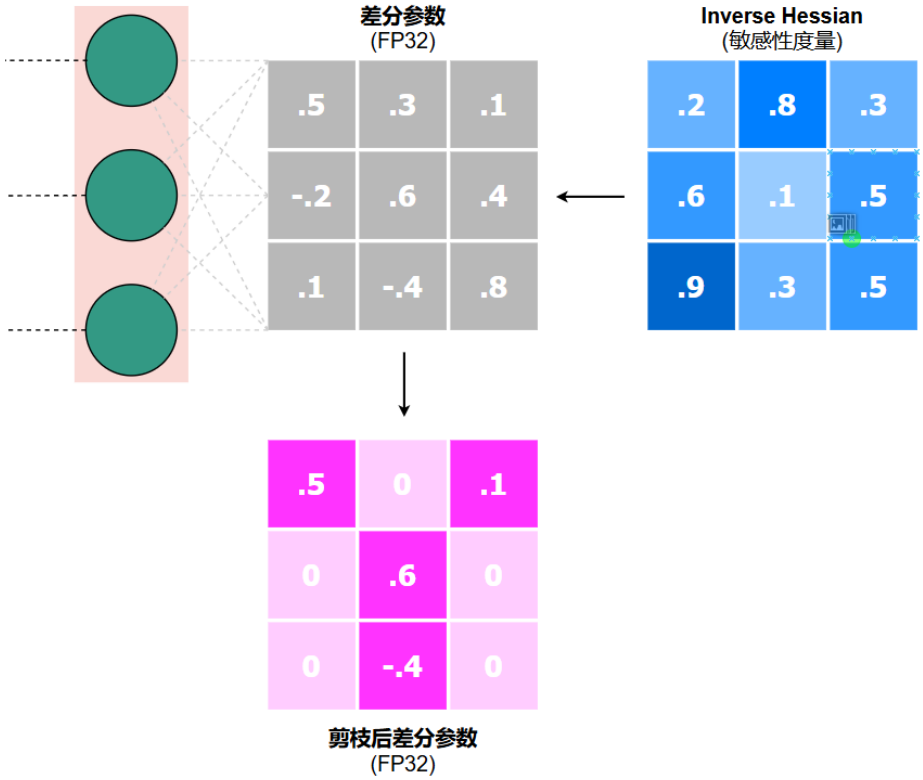

图 4 基于差分传输与模型感知的参数压缩策略总体方法

如图 4 所示，展示了基于差分传输与模型感知的参数压缩策略总体方案。首先，研究参数敏感度矩阵构建机制，通过捕获优化器中间值关于梯度的 L2 范数与梯度值，结合构建近似的模型参数关于损失函数的二阶导数矩阵，即 Hessian 矩阵，缩小计算 Hessian 矩阵的计算时间；其次，研究基于敏感度分析的量化与稀疏化方法，通过动态选取压缩率，设计不同的量化程度与稀疏化程度，实现云边端协同跨域场景下的高效参数压缩方法；最后，研究模型参数差分传输策略，通过捕获优化器对模型的更新量，再根据基于敏感度分析的量化与稀疏化策略，使用更新量的压缩值以代替全量的模型参数的压缩值。通过上述机制，实现云边端场景下进行分布式训练的模型参数同步效率，并保护模型在高压缩率场景下的模型参数精度，提升模型跨域分布式训练速度。具体研究方案如下：

1、敏感度矩阵构建机制

本节将详细介绍所提出的基于外积近似的 Hessian 矩阵构建方法。首先，当神经网络应用于回归问题时，通常使用形式如下的平方和损失函数：

$$\mathrm{E} = \frac{1}{2}\sum_{n=1}^{N}(y_n - t_n)^2 \qquad 1$$

其中为了记号的简洁，我们考虑单一输出的情形。这样，可以将 Hessian 矩阵写成：

$$\mathrm{H} = \nabla\nabla E = \sum_{n=1}^{N}\nabla y_n(\nabla y_n)^T + \sum_{n=1}^{N}(y_n - t_n)\nabla\nabla y_n \qquad 2$$

通过忽略式 2 的第二项，可得到 Levenberg-Marquardt 近似，即 Hessian 矩阵的外积近似形式，由下式 3 给出：

$$\mathrm{H} \cong \sum_{n=1}^{N} b_n\, b_n^T \qquad 3$$

计算外积近似的计算是容易的，因为其只涉及到误差函数的一阶导数，即为梯度，故而可以通过标准的反向传播算法在线性复杂度个步骤内高效的计算得到。因此，可以通过捕获优化器内计算的梯度中间量，用于更新参数的同时，计算 Hessian 矩阵从而得到各个参数的敏感性分析。

2、基于敏感度分析的量化与稀疏方法

将量化位数降低至 8-bit 以下或将稀疏化程度设置至 25%以下是一项艰巨的任务，因为每减少一个 bit 或减少稀疏化程度，量化误差与压缩误差就会增加。根据 Hessian 矩阵所描述参数矩阵中模型关于参数的敏感性程度，可以进行以下量化与稀疏剪枝方法，以保证模型精度。

量化方法：通过加权量化误差的方式来实现压缩的量化与反量化方法。首先，预计算每一层权重中，敏感度最高的参数在经过量化、反量化后所产生的精度误差；接着，将该量化误差以低精度量化随量化后模型发送，用于加权该层模型的反量化过程，保护了敏感度最高的模型参数，从而最大限度的降低了量化对于模型的损害。

稀疏方法：通过模型剪枝的方式来实现模型参数的稀疏化方法。首先，根据敏感度分析，对参数进行一轮筛选，通过设定一个阈值来确定敏感性较高和敏感性较低的参数；而后，将对应敏感性较低的参数值设为 0，保留敏感性较高的参数，已完成对参数矩阵的稀疏化。

上述的量化方法与稀疏化方法可以同时使用，从而获取更高的参数压缩率。

3、模型差分传输机制

本节将详细介绍所提出的模型差分传输机制。首先，设定一个基准模型参数，通过定期的捕获某一轮模型参数的值，来确定整体上模型基于差分更新的基础模型；其次，捕获待传输模型参数，通过不断的捕获优化器更新量并求和而得到多轮更新后的模型参数与基准模型参数的差；最后，对模型参数差分量应用敏感度分析的压缩方法，压缩更新量并减少对模型精度的损失。

2.2.2. 基于混合精度的自适应优化器方法

针对分布式训练中对优化器策略的挑战，拟提出一种基于训练的自适应优化器方法。首先，研究混合精度训练下的自适应优化器量化建模，通过建立量化场景下的自适应梯度下降方法，加速在压缩通信场景下模型的收敛性能；其次，研究优化器状态压缩策略，主要包含激活值、梯度与优化器中间量的压缩。通过上述机制，有效地加速云边端场景下的训练收敛性能，提升大规模分布式训练计算效率。

1、量化优化器建模

本节将详细介绍所提出的量化优化器建模方法。首先，介绍典型的 SignSGD 方法，与 Adam 方法。SignSGD 通过将梯度量化为-1 与 1，而 Adam 通过动量法，结合梯度的二阶矩估计，对梯度值加权更新模型。因此，本方法选择将 Adam 的加权梯度进行量化，构造以下更新公式：

$$m_t \rightarrow \beta m_{t-1} + (1-\beta) g_t$$

$$b_t \rightarrow \beta b_{t-1} + (1-\beta) |g_t|$$

$$x_{t+1} \rightarrow x_t - \alpha_t Q\left(\frac{m_t}{b_t}\right)$$

该更新公式通过将$\frac{m_t}{b_t}$更新值进行量化，从而在类 Adam 的自适应更新下适配梯度的压缩传输

2、混合精度优化器同步

本节将详细介绍所提出的混合精度优化器同步机制。本方法通过令 *Q(m/b)* 在统计学上成为原 Adam 中动量更新步长的无偏估计量，可以使得在分布式节点中任意精度的优化器更新步长一致。从而使得不同精度的优化器策略在不同节点上的更新得以同步。

2.2.3. 基于并行策略计划与网络状态感知的跨域集合通信方法

针对上述两个挑战，拟提出一种基于并行策略计划与网络状态感知的跨域集合通信方法。首先，进行集合通信动态拓扑设计，在运行时，进行网络状态感知，结合并行策略与网络状态构建进行集合通信时节点间的通信拓扑，实现动态感知并行策略与网络状态的集合通信拓扑设计，以实现广域网环境下各节点间高效协同；其次，进行集合通信调度设计，在运行时，考虑到广域网中节点间互联程度低，对域内通信进行初步的调度，控制节点间的通信发起顺序，降低通信间并发程度。

1、集合通信动态拓扑生成设计

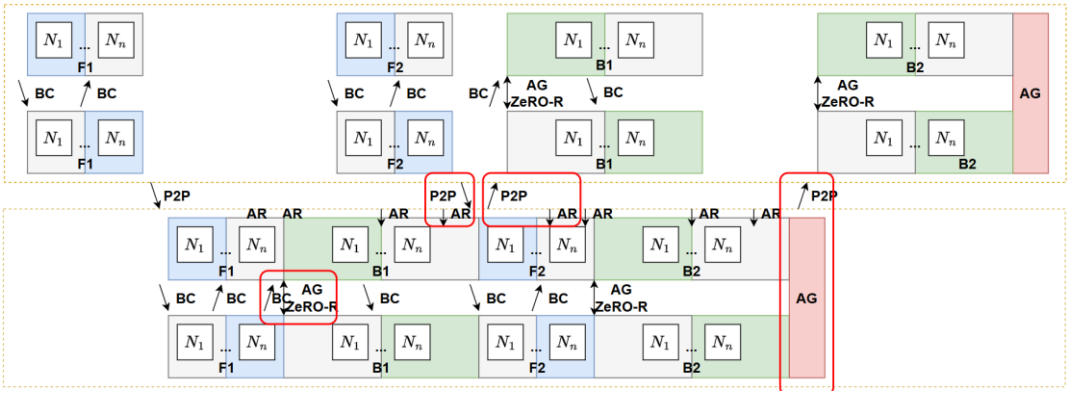

图 5 运行时通信拓扑重生成机制

本节将详细介绍基于二重二叉树规约（Double Binary Tree AllReduce）划分

的运行时通信拓扑重生成机制。分析并行策略与模型划分情况，将各节点划分为不同子集，针对不同子集内部，探测实时网络情况并动态更新通信拓扑。具体来说，通过动态规划树形集合通信架构（补充）本节将详细介绍基于二重二叉树规约（Double Binary Tree AllReduce）划分的运行时通信拓扑重生成机制。分析并行策略与模型划分情况，将各节点划分为不同子集，针对不同子集内部，探测实时网络情况并动态更新通信拓扑。具体来说，通过动态规划树形集合通信架构（补充），这种机制能够优化并行计算中的通信效率，特别是在大规模分布式系统中。动态规划树形集合通信架构能够在运行时根据网络状况和计算需求，调整通信路径和数据传输策略，以实现更高效的数据交换和降低通信延迟。

在这种架构中，通信拓扑的动态规划涉及到对树形结构的智能管理和优化。通过探测实时网络情况，系统可以识别出网络中的瓶颈和高延迟链接，并据此调整通信路径，避免这些链接或寻找替代路径。这种动态调整可以是基于预设的性能指标，如带宽利用率、延迟和丢包率等。

此外，动态规划树形集合通信架构还包括对算法和协议的优化选择。在执行 AllReduce 操作时，系统会计算不同算法和协议组合的执行时间，并选择最优的组合以提高性能。这种优化不仅涉及到单个节点内部的数据处理，还包括节点间的通信策略，如在 Reduce 阶段和 Broadcast 阶段选择最合适的数据传输方式。

综上所述，基于二重二叉树规约的运行时通信拓扑重生成机制通过动态规划树形集合通信架构，能够实现对并行计算中通信拓扑的智能管理和优化，从而提高大规模分布式系统中的通信效率和计算性能。

2、集合通信动态调度设计

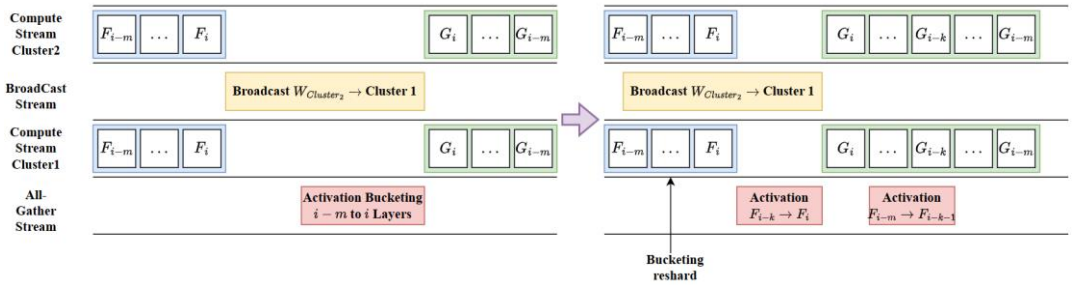

图 6 集合通信动态调度机制

本节将详细介绍基于集合通信动态调度机制。分析混合并行中，是否存在并发通信流，从而导致的带宽争用情况，造成次轮训练因通信而拖延。而后，通过

张量分割，将待传输张量分割成块，以此将通信操作分为多个微操作，结合计算-通信的并行，进行通信操作的重调度，从而降低在混合并行中执行集合通信原语的时间。具体来说：首先，需要对混合并行环境中的通信模式进行深入分析，识别出哪些通信流是并发的，以及它们对带宽的需求。

通过模拟或实际运行时监控，收集通信流的数据，包括通信量、通信频率和通信模式（如点对点、小规模集合、大规模集合）。而后，进行带宽争用识别，确定在哪些时间点上，多个通信流同时发生，导致带宽争用。分析带宽争用对训练轮次的影响，特别是对次轮训练的延迟。再应用张量分割策略，将大的待传输张量分割成小块，这样可以减少单次通信的数据量，降低对带宽的压力。最后根据通信模式和带宽使用情况，动态调整集合通信的先后顺序，以优化通信效率。通过这些步骤，可以有效地降低混合并行中集合通信原语的执行时间，提高整体的训练效率。

3. 论文工作安排

在本节中，将详细介绍论文工作安排，分工作进度安排、论文工作基础、可能遇到的问题以及解决途径 3 个方面进行论述。

3.1. 工作进度安排

本论文的时间安排，如下表所示：

表 1 论文研究时间安排

时间	研究计划	当前进展情况	完成状态
2024 年 1 月-2024 年 8 月	调研和分析当前国内外面向云边端协同的跨域分布式训练相关通信优化技术	对相关量化稀疏化压缩方法、优化器量化与自适应调整方法、集合通信优化方案生成进行了调研和分析	已完成
2024 年 6 月-2024 年 12 月	研究基于差分传输模型感知的模型参数压缩策略，实现部署压缩策略的云边端训练	完成了基于差分传输模型感知的模型参数压缩策略方案设计，正在进行编码	完成方案设计进行编码实现

2024 年 11 月-2025 年 4 月	研究基于混合精度的自适应优化器方法，实现压缩、更新一体化的分布式训练，撰写论文	完成了基于混合精度的自适应优化器基本方法设计，正在进行进一步理论推导	基本完成方案设计
2025 年 4 月-2025 年 10 月	研究基于并行策略与网络状态感知的跨域集合通信方法，实现并行策略的动态生成和切换	完成了基于并行策略与网络状态感知的跨域集合通信基本方法设计，正在进行实验	基本完成方案设计
2024 年 6 月-2025 年 12 月	研发面向云边端协同的跨域分布式训练通信优化架构，验证相关方法效果	完成项目基础结构设计，正在进行压缩策略实现	完成架构设计开始编码实现
2025 年 12 月-2026 年 2 月	整理上述成果，撰写毕业论文	未开始	未开始

3.2. 论文工作基础

在本节中，将主要介绍已有的研究和工作基础。分为研究方案的具体进展、已录用或已投稿的论文、申请的国家发明专利、申请或参与项目情况 4 个部分。

3.2.1. 研究方案的具体进展

1、基于差分传输与模型感知的参数压缩策略

目前，正在进行基于差分传输与模型感知的参数压缩策略的研发和实验工作；完成了基于差分传输模型感知的模型参数压缩策略方案设计，正在进行编码，预计可带来 1-6.5x 的通信速度提升。

2、基于混合精度的自适应优化器方法

目前，正在进行基于混合精度的自适应优化器的研发和实验工作；完成了基于混合精度的自适应优化器基本方法设计，正在进行进一步理论推导。

3、基于约束指导和冗余计算的跨域并行策略生成技术

完成了基于并行策略与网络状态感知的跨域集合通信基本方法设计，正在进行 sh。

3.2.2. 已录用或已投稿的论文

目前，本人累计投稿相关论文成果 1 篇。包含 1 篇 CCF C 类期刊论文大修返回。

[1] Xiao L, **Li Y**, Huo Z, et al. FusionTransmit: A Compression-Aware Distributed Training Scheduler for PowerSGD. CCF Transactions on High Performance Computing.

3.2.3. 申请或参与项目情况

[1] 作为项目骨干申请和研究国家重点研发计划项目《面向云边端协同的芯粒结构与系统软件》（项目编号：2023YFB4503100），并将本论文相关研究内容应用到项目关键内容中。

3.3. 可能遇到的问题以及解决途径

本论文可能遇到的问题以及解决途径如下：

① 研究方案无法很好的适配真实场景的问题

当研究方案无法很好地适配实际场景时，首先，与实际验证场景的专家、老师进行沟通，收集他们的反馈和建议，了解方案在实际应用中的局限性；其次，调整研究设计，根据反馈和分析结果，调整研究设计，方案更贴合实际场景的需求和条件；然后，对调整后的方法进行工程实现和小规模验证，保持论文计划的灵活性，根据实际情况的变化适时调整；最后，进行大规模的验证和实验，确保实验结果在真实场景中的效果和可靠性。

② 相关计算环境和场景的建模问题

首先，为确保对应用的评估的准确性，拟采用主流的智算应用数据和训推模型作为实验样本，并在运行过程中多方面监测，形成参考样本；其次，为实现对优化方法的细致建模，广泛地评估云边端计算环境的各项指标，分析影响模型构建的各要素，并调整相应的公式，从而实现更精细化建模。

③ 相关技术点在工程实现方面存在困难的问题

首先，详细调研相关工作的实现方式，了解 DeepSpeed、Pytorch 等框架、

nccl 等底层通信框架的实现方式和 API 设计原则，了解基本的原理和工作流程及其面向解决的问题；其次，补充相应的基础知识，如编译原理、GPU 结构等方面；最后，进行敏捷的开发，确保各部分工程实现解耦，确保良好的接口设计，同时进行详细的测试与评估，形成快速的反应链条。

主要参考文献

[1] Office of Science and Technology Policy. National Strategic Computing Initiative Update[EB]. 2019

[2] Office of Science and Technology Policy. Pioneering the Future Advanced Computing Ecosystem: A Strategic Plan[EB]. 2020

[3] DEPARTMENT OF DEFENSE. 5G Strategy Implementation Plan[EB]. 2020

[4] Office of Science and Technology Policy. Critical and Emerging Technologies List[EB]. 2024

[5] Home | European Citizens' Initiative[EB/OL]. https://citizens-initiative.europa.eu/_en, 2024-08-02

[6] European Commission. Horizon Europe Work Programme 2021-2022[EB]. 2022

[7] IPCEI - European Commission[EB/OL]. https://competition-policy.ec.europa.eu/state-aid/ipcei_en, 2024-08-02

[8] Azure Public Multi-Access Edge Compute (MEC) | Microsoft Azure[EB/OL]. https://azure.microsoft.com/en-gb/solutions/public-multi-access-edge-compute-mec, 2024-08-02

[9] 适合于边缘站点的 AWS – 边缘计算和存储、5G、混合环境、物联网 - Amazon Web Services[EB/OL]. https://aws.amazon.com/cn/edge/, 2024-08-02

[10] Deploy O. Continuous Delivery & Deployment Automation Tool for DevOps Teams[EB/OL]. https://octopus.com, 2024-08-02

[11] AWS 上的 Volkswagen Group：案例研究、视频。创客案例[EB/OL]. https://aws.amazon.com/cn/solutions/case-studies/innovators/volkswagen-group/, 2024-08-02

[12] iRobot 和 AWS IoT 轻松应对每年的流量高峰时段 | 视频 | AWS[EB/OL]. https://aws.amazon.com/cn/solutions/case-studies/irobot-iot/, 2024-08-02

[13] Amazon Web Services. Reinventing Cloud Native 5G Networks with AWS and DISH[EB]. 2021

[14] KubeEdge[EB/OL]. https://kubeedge.io/, 2024-08-02

[15] SuperEdge[EB/OL]. https://superedge.io/, 2024-08-02

[16] An open platform that extends upstream Kubernetes to Edge | OpenYurt [EB/OL]. https://openyurt.io/zh/, 2024-08-02

[17] 肖利民, 宋尧, 秦广军, et al. GVDS：面向广域高性能计算环境的虚拟数

据空间[J]. 大数据, 2021,7(2): 123-146
[18] IDC：人工智能算力向边缘侧迁移，将带动中国边缘服务器稳步增长[EB/OL]. https://www.idc.com/getdoc.jsp?containerId=prCHC52069324, 2024-08-02
[19] IDC：5G 和人工智能技术推动中国边缘服务器市场逆势增长[EB/OL]. https://www.idc.com/getdoc.jsp?containerId=prCHC50867923, 2024-08-02
[20] PyTorch Edge[EB/OL]. https://pytorch.org/edge, 2024-08-02
[21] PyTorch[EB/OL]. https://pytorch.org/, 2024-08-02
[22] Chen T., Moreau T., Jiang Z., et al. TVM: An Automated End-to-End Optimizing Compiler for Deep Learning[J]
[23] Apache TVM[EB/OL]. https://tvm.apache.org/, 2024-08-02
[24] TensorFlow Lite | TensorFlow 中文官网[EB/OL]. https://www.tensorflow.org/lite?hl=zh-cn, 2024-08-02
[25] NVIDIA Embedded Systems for Next-Gen Autonomous Machines[EB/OL]. https://www.nvidia.com/en-us/autonomous-machines/embedded-systems/, 2024-08-02
[26] NVIDIA Jetson AGX Orin[EB/OL]. https://www.nvidia.com/en-us/autonomous-machines/embedded-systems/jetson-orin/, 2024-08-02
[27] NVIDIA TensorRT[EB/OL]. https://developer.nvidia.com/tensorrt, 2024-08-02
[28] AMD Ryzen™ AI - Windows PCs with AI Built In[EB/OL]. https://www.amd.com/en/products/processors/consumer/ryzen-ai.html, 2024-08-02
[29] AMD ROCm™ Software[EB/OL]. https://www.amd.com/en/products/software/rocm.html, 2024-08-02
[30] Yu J., Prabhu K., Urman Y., et al. 8-Bit Transformer Inference and Fine-Tuning for Edge Accelerators[A]. Proceedings of the 29th ACM International Conference on Architectural Support for Programming Languages and Operating Systems, Volume 3[C]. La Jolla CA USA: ACM, 2024: 5-21
[31] Choudhury A., Wang Y., Pelkonen T., et al. MAST: Global Scheduling of ML Training across Geo-Distributed Datacenters at Hyperscale[J]
[32] Kirkpatrick J., Pascanu R., Rabinowitz N., et al. Overcoming Catastrophic Forgetting in Neural Networks[J]. Proceedings of the National Academy of Sciences, 2017,114(13): 3521-3526
[33] Gong T., Kim Y., Shin J., et al. MetaSense: Few-Shot Adaptation to Untrained Conditions in Deep Mobile Sensing[A]. Proceedings of the 17th Con

ference on Embedded Networked Sensor Systems[C]. New York, NY, USA: Association for Computing Machinery, 2019: 110-123

[34] Zhu L., Hu L., Lin J., et al. PockEngine: Sparse and Efficient Fine-Tuning in a Pocket[A]. 56th Annual IEEE/ACM International Symposium on Microarchitecture[C]. Toronto ON Canada: ACM, 2023: 1381-1394

[35] GPUDirect RDMA[EB/OL]. https://docs.nvidia.com/cuda/gpudirect-rdma/, 2024-08-03

[36] K R. InfiniBand Trade Association[EB/OL]. https://www.infinibandta.org/, 2024-08-03

[37] NVLink & NVSwitch for Advanced Multi-GPU Communication[EB/OL]. https://www.nvidia.com/en-us/data-center/nvlink/, 2024-08-03

[38] Homepage - Compute Express Link[EB/OL]. https://computeexpresslink.org/, 2023-09-19/2024-08-03

[39] 10 Gigabit Ethernet - Wikipedia[EB/OL]. https://en.wikipedia.org/wiki/10_Gigabit_Ethernet, 2024-08-03

[40] Liang P., Tang Y., Zhang X., et al. A Survey on Auto-Parallelism of Large-Scale Deep Learning Training[J]. IEEE Transactions on Parallel and Distributed Systems, 2023,34(8): 2377-2390

[41] Paszke A., Gross S., Massa F., et al. PyTorch: An Imperative Style, High-Performance Deep Learning Library[A]. Advances in Neural Information Processing Systems: Vol. 32[C]. Curran Associates, Inc., 2019

[42] 关于 TensorFlow | TensorFlow 中文官网[EB/OL]. https://www.tensorflow.org/?hl=zh-cn, 2024-08-06

[43] Abadi M., Agarwal A., Barham P., et al. TensorFlow: Large-Scale Machine Learning on Heterogeneous Distributed Systems[EB]. arXiv, 2016

[44] PaddlePaddle/Paddle: PArallel Distributed Deep LEarning: Machine Learning Framework from Industrial Practice （『飞桨』核心框架，深度学习&机器学习高性能单机、分布式训练和跨平台部署）[EB/OL]. https://github.com/PaddlePaddle/Paddle, 2024-08-06

[45] Mindspore-Ai/Mindspore: MindSpore Is a New Open Source Deep Learning Training/Inference Framework That Could Be Used for Mobile, Edge and Cloud Scenarios.[EB/OL]. https://github.com/mindspore-ai/mindspore, 2024-08-06

[46] Google/Jax: Composable Transformations of Python+NumPy Programs: Di

fferentiate, Vectorize, JIT to GPU/TPU, and More[EB/OL]. https://github.com/google/jax, 2024-08-06

[47] Microsoft/DeepSpeed: DeepSpeed Is a Deep Learning Optimization Library That Makes Distributed Training and Inference Easy, Efficient, and Effective.[EB/OL]. https://github.com/microsoft/DeepSpeed, 2024-08-06

[48] NVIDIA/Megatron-LM: Ongoing Research Training Transformer Models at Scale[EB/OL]. https://github.com/NVIDIA/Megatron-LM, 2024-08-06

[49] Shoeybi M., Patwary M., Puri R., et al. Megatron-LM: Training Multi-Billion Parameter Language Models Using Model Parallelism[EB]. arXiv, 2020

[50] Hpcaitech/ColossalAI: Making Large AI Models Cheaper, Faster and More Accessible[EB/OL]. https://github.com/hpcaitech/ColossalAI, 2024-08-06

[51] Jiang X., Wang H., Chen Y., et al. MNN: A Universal and Efficient Inference Engine[EB/OL]. https://arxiv.org/abs/2002.12418v1, 2020-02-27/2024-08-12

[52] Patil S. G., Jain P., Dutta P., et al. POET: Training Neural Networks on Tiny Devices with Integrated Rematerialization and Paging[A]. Proceedings of the 39th International Conference on Machine Learning[C]. PMLR, 2022: 17573-17583

[53] Wang S., Feng T., Yang H., et al. AtRec: Accelerating Recommendation Model Training on CPUs[J]. IEEE Transactions on Parallel and Distributed Systems, 2024,35(6): 905-918

[54] Zhang L., Lu K., Lai Z., et al. Accelerating GNN Training by Adapting Large Graphs to Distributed Heterogeneous Architectures[J]. IEEE Transactions on Computers, 2023,72(12): 3473-3488

[55] Zhang D., Huang X., Liu Z., et al. AGL: A Scalable System for Industrial-Purpose Graph Machine Learning[J]. Proc. VLDB Endow., 2020,13(12): 3125-3137

[56] Mao J., Chen X., Nixon K. W., et al. MoDNN: Local Distributed Mobile Computing System for Deep Neural Network[A]. Design, Automation & Test in Europe Conference & Exhibition (DATE), 2017[C]. Lausanne, Switzerland: IEEE, 2017: 1396-1401

[57] Zeng L., Chen X., Zhou Z., et al. CoEdge: Cooperative DNN Inference With Adaptive Workload Partitioning Over Heterogeneous Edge Devices[J]. IEEE/ACM Transactions on Networking, 2021,29(2): 595-608

[58] Zhao Z., Barijough K. M., Gerstlauer A. DeepThings: Distributed Adaptive Deep Learning Inference on Resource-Constrained IoT Edge Clusters[J]. IEEE Transactions on Computer-Aided Design of Integrated Circuits and Systems, 2018,37(11): 2348-2359

[59] Hao P., Zhang Y. EDDL: A Distributed Deep Learning System for Resource-Limited Edge Computing Environment[A]. 2021 IEEE/ACM Symposium on Edge Computing (SEC)[C]. 2021: 1-13

[60] Yang L., Gan Y., Chen J., et al. AutoSF: Adaptive Distributed Model Training in Dynamic Edge Computing[J]. IEEE Transactions on Mobile Computing, 2024,23(6): 6549-6562

[61] Chen Y., Yang Q., He S., et al. FTPipeHD: A Fault-Tolerant Pipeline-Parallel Distributed Training Approach for Heterogeneous Edge Devices[J]. IEEE Transactions on Mobile Computing, 2024,23(4): 3200-3212

[62] Rajbhandari S., Rasley J., Ruwase O., et al. ZeRO: Memory Optimizations toward Training Trillion Parameter Models[A]. Proceedings of the International Conference for High Performance Computing, Networking, Storage and Analysis[C]. Atlanta, Georgia: IEEE Press, 2020: 1-16

[63] Ren J., Rajbhandari S., Aminabadi R. Y., et al. ZeRO-Offload: Democratizing Billion-Scale Model Training[EB]. arXiv, 2021

[64] Rajbhandari S., Ruwase O., Rasley J., et al. ZeRO-Infinity: Breaking the GPU Memory Wall for Extreme Scale Deep Learning[A]. Proceedings of the International Conference for High Performance Computing, Networking, Storage and Analysis[C]. St. Louis Missouri: ACM, 2021: 1-14

[65] Wang G., Qin H., Jacobs S. A., et al. ZeRO++: Extremely Efficient Collective Communication for Giant Model Training[EB]. arXiv, 2023

[66] Wang J., Lu Y., Yuan B., et al. CocktailSGD: Fine-Tuning Foundation Models over 500mbps Networks[A]. Proceedings of the 40th International Conference on Machine Learning: Vol. 202[C]. Honolulu, Hawaii, USA: JMLR.org, 2023: 36058-36076

[67] Song J., Yim J., Jung J., et al. Optimus-CC: Efficient Large NLP Model Training with 3D Parallelism Aware Communication Compression[A]. Proceedings of the 28th ACM International Conference on Architectural Support for Programming Languages and Operating Systems, Volume 2[C]. Vancouver BC Canada: ACM, 2023: 560-573

[68] Yu Y., Wu J., Huang L. Double Quantization for Communication-Efficient Distributed Optimization[A]. Advances in Neural Information Processing Systems: Vol. 32[C]. Curran Associates, Inc., 2019

[69] Chen C.-Y., Ni J., Lu S., et al. ScaleCom: Scalable Sparsified Gradient Compression for Communication-Efficient Distributed Training[A]. Advances in Neural Information Processing Systems: Vol. 33[C]. Curran Associates, Inc., 2020: 13551-13563

[70] Hu K., Wu C., Zhu E. HGC: Hybrid Gradient Compression in Distributed Deep Learning[A]. Sun X., Zhang X., Xia Z., et al. Advances in Artificial Intelligence and Security[C]. Cham: Springer International Publishing, 2021: 15-27

[71] Gan S., Jiang J., Yuan B., et al. Bagua: Scaling up Distributed Learning with System Relaxations[J]. Proc. VLDB Endow., 2021,15(4): 804-813

[72] Duan Q., Peng C., Wang Z., et al. Accelerating Distributed DNN Training via Transport Layer Scheduling[J]. IEEE Transactions on Parallel and Distributed Systems, 2023,34(5): 1650-1666

[73] Chen C., Li X., Zhu Q., et al. Centauri: Enabling Efficient Scheduling for Communication-Computation Overlap in Large Model Training via Communication Partitioning[A]. Proceedings of the 29th ACM International Conference on Architectural Support for Programming Languages and Operating Systems, Volume 3[C]. La Jolla CA USA: ACM, 2024: 178-191

[74] Fang J., Zhao G., Xu H., et al. GRID: Gradient Routing With In-Network Aggregation for Distributed Training[J]. IEEE/ACM Transactions on Networking, 2023,31(5): 2267-2280

[75] Lao C., Le Y., Mahajan K., et al. {ATP}: In-Network Aggregation for Multi-Tenant Learning[A]. 18th USENIX Symposium on Networked Systems Design and Implementation (NSDI 21)[C]. 2021: 741-761

[76] Liu J., Zhai Y., Zhao G., et al. InArt: In-Network Aggregation with Route Selection for Accelerating Distributed Training[A]. Proceedings of the ACM on Web Conference 2024[C]. Singapore Singapore: ACM, 2024: 2879-2889

[77] Gebara N., Ghobadi M., Costa P. In-Network Aggregation for Shared Machine Learning Clusters[J]. Proceedings of Machine Learning and Systems, 2021,3: 829-844

[78] Wang S., Wei J., Sabne A., et al. Overlap Communication with Dependent Computation via Decomposition in Large Deep Learning Models[A]. Proceedings of the 28th ACM International Conference on Architectural Support for Programming Languages and Operating Systems, Volume 1[C]. New York, NY, USA: Association for Computing Machinery, 2022: 93-106

[79] Feng Y., Xie M., Tian Z., et al. Mobius: Fine Tuning Large-Scale Models on Commodity GPU Servers[A]. Proceedings of the 28th ACM International Conference on Architectural Support for Programming Languages and Operating Systems, Volume 2[C]. Vancouver BC Canada: ACM, 2023: 489-501

[80] Oh H., Lee J., Kim H., et al. Out-of-Order Backprop: An Effective Scheduling Technique for Deep Learning[A]. Proceedings of the Seventeenth European Conference on Computer Systems[C]. New York, NY, USA: Association for Computing Machinery, 2022: 435-452

[81] Li F., Zhao S., Qing Y., et al. Fold3D: Rethinking and Parallelizing Computational and Communicational Tasks in the Training of Large DNN Models[J]. IEEE Transactions on Parallel and Distributed Systems, 2023,34(5): 1432-1449

[82] Lai Z., Li S., Tang X., et al. Merak: An Efficient Distributed DNN Training Framework With Automated 3D Parallelism for Giant Foundation Models[J]. IEEE Transactions on Parallel and Distributed Systems, 2023,34(5): 1466-1478

[83] Zhang Z., Xia Y., Wang H., et al. MPMoE: Memory Efficient MoE for Pre-Trained Models With Adaptive Pipeline Parallelism[J]. IEEE Transactions on Parallel and Distributed Systems, 2024,35(6): 998-1011

[84] Li M. Scaling Distributed Machine Learning with the Parameter Server[A]. Proceedings of the 2014 International Conference on Big Data Science and Computing[C]. Beijing China: ACM, 2014: 1-1

[85] Wang M., Huang C., Li J. Supporting Very Large Models Using Automatic Dataflow Graph Partitioning[A]. Proceedings of the Fourteenth EuroSys Conference 2019[C]. New York, NY, USA: Association for Computing Machinery, 2019: 1-17

[86] Cai Z., Yan X., Ma K., et al. TensorOpt: Exploring the Tradeoffs in Distributed DNN Training With Auto-Parallelism[J]. IEEE Transactions on Paral

lel and Distributed Systems, 2022,33(8): 1967-1981

[87] Narayanan D., Harlap A., Phanishayee A., et al. PipeDream: Generalized Pipeline Parallelism for DNN Training[A]. Proceedings of the 27th ACM S ymposium on Operating Systems Principles[C]. New York, NY, USA: Assoc iation for Computing Machinery, 2019: 1-15

[88] Narayanan D., Phanishayee A., Shi K., et al. Memory-Efficient Pipeline-P arallel DNN Training[EB]. arXiv, 2021

[89] Tarnawski J., Phanishayee A., Devanur N., et al. Efficient Algorithms for Device Placement of DNN Graph Operators[A]. Proceedings of the 34th I nternational Conference on Neural Information Processing Systems[C]. Red Hook, NY, USA: Curran Associates Inc., 2020: 15451-15463

[90] Tarnawski J. M., Narayanan D., Phanishayee A. Piper: Multidimensional Planner for DNN Parallelization[A]. Advances in Neural Information Process ing Systems: Vol. 34[C]. Curran Associates, Inc., 2021: 24829-24840

[91] Wang H., Li C., Tachon T., et al. Efficient and Systematic Partitioning o f Large and Deep Neural Networks for Parallelization[A]. Euro-Par 2021: P arallel Processing: 27th International Conference on Parallel and Distributed Computing, Lisbon, Portugal, September 1–3, 2021, Proceedings[C]. Berlin, Heidelberg: Springer-Verlag, 2021: 201-216

[92] Elango V. Pase: Parallelization Strategies for Efficient DNN Training[A]. 2021 IEEE International Parallel and Distributed Processing Symposium (IP DPS)[C]. 2021: 1025-1034

[93] Song L., Chen F., Zhuo Y., et al. AccPar: Tensor Partitioning for Hetero geneous Deep Learning Accelerators[A]. 2020 IEEE International Symposiu m on High Performance Computer Architecture (HPCA)[C]. 2020: 342-355

[94] Zheng L., Li Z., Zhang H., et al. Alpa: Automating Inter- and {Intra-Op erator} Parallelism for Distributed Deep Learning[A]. 16th USENIX Sympos ium on Operating Systems Design and Implementation (OSDI 22)[C]. 2022: 559-578

[95] Lin Z., Miao Y., Zhang Q., et al. nnScaler: Constraint-Guided Parallelizat ion Plan Generation for Deep Learning Training[A]. 18th USENIX Symposi um on Operating Systems Design and Implementation[C]. 2024

[96] Addanki R., Venkatakrishnan S. B., Gupta S., et al. Placeto: Learning Ge neralizable Device Placement Algorithms for Distributed Machine Learning

[M]. Proceedings of the 33rd International Conference on Neural Informatio n Processing Systems. Red Hook, NY, USA: Curran Associates Inc., 2019: 3981-3991

[97] Zhou Y., Roy S., Abdolrashidi A., et al. GDP: Generalized Device Place ment for Dataflow Graphs[EB/OL]. https://arxiv.org/abs/1910.01578v1, 2019-09-28/2024-08-10

[98] Paliwal A., Gimeno F., Nair V., et al. Reinforced Genetic Algorithm Lea rning for Optimizing Computation Graphs[EB]. arXiv, 2020

[99] Liu J., Wu Z., Feng D., et al. HeterPS: Distributed Deep Learning with Reinforcement Learning Based Scheduling in Heterogeneous Environments[J]. Future Gener. Comput. Syst., 2023,148(C): 106-117

[100] Wang S., Rong Y., Fan S., et al. Auto-MAP: A DQN Framework for Ex ploring Distributed Execution Plans for DNN Workloads[EB/OL]. https://arxi v.org/abs/2007.04069v1, 2020-07-08/2024-08-10

[101] Zhang S., Yi X., Diao L., et al. Expediting Distributed DNN Training W ith Device Topology-Aware Graph Deployment[J]. IEEE Transactions on Par allel and Distributed Systems, 2023,34(4): 1281-1293

北京航空航天大学计算机学院

硕士研究生学位论文
文献综述

论文题目：面向云边端协同的跨域分布式训练通信优化技术研究

专　　业：计算机体系结构

研究方向：分布式计算

研 究 生：李云潼

学　　号：SY2306142

指导教师：肖利民

北京航空航天大学计算机学院

2024 年 11 月 27 日

目录

1. 研究方向概述 1
2. 国内外研究现状 8
2.1. 云边端计算环境通信优化策略相关工作 8
2.1.1. 减少通信量的相关工作 8
2.1.2. 优化通信模式的相关工作 9
2.1.3. 增强计算和通信的重叠性的相关工作 10
3. 研究现状总结与分析 12
3.1. 论文研究领域存在的问题 12
3.1.1. 如何实现云边端跨域高效参数通信 12
3.1.2. 如何实现云边端通信高效的优化器策略 13
3.1.3. 如何动态地生成云边端跨域训练并行策略 14
3.2. 论文研究领域的发展趋势 14
3.3. 研究现状分析结论 15
主要参考文献 16

1. 研究方向概述

云边端计算环境是服务国家关键领域数智化转型的重要基础设施，支撑了电网、交通、制造等关键领域的发展，创造了全新的新质生产力，且已经成为了全球范围内的研究热点和竞争焦点。

云边端计算环境成为各个国家和地区的竞争焦点。为了应对日益增长的云边端计算环境需求，世界各国政府纷纷制定了相关的文件、计划、政策。例如，美国自 2019 年来相继发布了《国家战略性计算计划：引领未来计算》[1]、《引领未来先进计算生态系统：战略计划》[2]、《美国防部 5G 战略实施计划》[3]、《关键和新兴技术清单》[4]等关键政策性文件，引导、推动美国边缘计算、雾计算、云边端协同等相关技术的发展。在欧洲方面，欧盟委员会相继发布了“ECI 计划”[5]、“地平线计划”[6]、“欧洲共同利益重要计划”[7]等相关的科技计划，批准了多达 12 亿以上欧元的专门资金，用以推动云计算、边缘计算的发展。我国同样注重发展云边端计算环境，“党的二十大报告”[8]、《“十四五”数字经济发展规划》[9]、《数字中国建设整体布局规划》[10]、《新型数据中心发展三年行动计划（2021-2023）》[11]等政策文件都不约而同的提及了云边端计算环境，并对其发展擘画蓝图。

云边端协同技术已经得到了长足的发展和进步。云边端协同跨域计算是支撑算力基础设施实现关键领域数智化的关键技术之一，涵盖计算、存储、网络、任务等多维度。当前，云边端协同跨域计算领域发展迅速，市场上出现了许多相关的系统平台，如微软云的 Public MEC 平台[12]、亚马逊的 AWS for Edge 平台[13]、Rancher 的 Octopus[14]等，支撑了如大众智能工厂[15]、iRobot 智能服务机器人[16]、DISH 云原生网络[17]的发展，实现了高效的云边端协同。

我国在云边端协同计算领域总体处于国际并跑状态。目前国内企业和高校推出了相关系统平台，如华为的 KubeEdge[18]、腾讯的 SuperEdge[19]、阿里的 OpenYurt[20]以及北航的跨域虚拟数据空间 GVDS[21]等。在知识产权方面，Google Patents 显示云边端协同跨域计算相关专利已超过 2500 件，IBM、Intel、AT&T 等美国企业拥有相关专利 200 余件，国家电网、北航等国内单位在此领域拥有部分

专利，但数量明显少于国外单位。

智能化成为未来云边端计算环境重要的竞争方向。根据 IDC 的调研，人工智能技术带动了新一波的云边端计算环境发展浪潮，2023 年我国云边端计算市场同比增长 29.1%，预计到 2028 年，市场规模将达到 132 亿美元[22, 23]。在智能化浪潮下，众多软硬件厂商共同发力提供了多种云边服务器和模型训推软件。在软件方面，Meta 联合 Arm、Apple、Qualcomm 等厂商发布了 ExecuTorch[24]将 PyTorch[25]的能力拓展到边缘，提升跨硬件设备的兼容性并降低框架开销，以实现快速的边缘推理；Apache 基金会主导开发了 TVM 引擎[26, 27]，架起了多种深度学习框架和异构硬件之间桥梁，为在多样化的嵌入式设备中运行 AI 模型推理任务提供了可能；Google 同样开发了 TensorFlow Lite[28]人工智能框架，提供了模型选择、转换、加速、优化等能力，为边端侧的模型优化、部署、推理奠定了良好的基础。在硬件方面，NVIDIA 推出了 Jetson[29]、Orin[30]等平台和芯片，成功地将智能模型拓展到边端侧，成为边缘计算智能硬件的标杆；并且，NVDIA 还推出了针对边缘计算优化的 TensorRT[31]工具包，通过与 Jetson 等平台的协同优化，以提供卓越的模型推理性能；AMD 则推出了基于 XDNA 架构的 AMD Ryzen AI SoC[32]与 ROCm 工具包[33]，为个人 PC、边缘服务器提供强大的智能算力；国内厂商如天数智芯[34]、寒武纪[35]、沐曦[36]、华为[37]等都推出了自主研发的 GPGPU 和 NPU，为边缘侧推理提供了强大的算力。

综上，在云边端计算环境已经成为了国内外研究和竞争的焦点，并且智能化已经成为了不可阻挡的浪潮，我国需要持续发力，迎头赶上。在云边端计算环境中，已经可以通过 TVM[24, 27, 28]等软件、Jetson[29, 32, 34–37]等硬件实现高效的模型推理；但是，随着边端侧硬件算力的增强、基础框架软件的发展、网络连接速度的提升，将模型训练、微调从云侧拓展到边端侧将逐步成为可能。

云边端协同的跨域分布式模型训练具有隐私性好、成本低、准确度高等优势。首先，云边端协同的跨域模型训练有利于保护敏感数据，提升隐私性；在云边端计算环境中，大部分数据来自于边端侧，这些数据通常涉及用户隐私和众多领域知识而成为敏感数据，如果遵循“端侧采集-边侧清洗-云侧训练”的模式，敏感数据将在云边端计算环境中经历多次计算、传输、存储，十分不利于用户的隐私

和领域知识的保护[38]；采用跨域分布式模型训练时，模型训练可以在边端侧完成，避免了数据的多次计算、传输、存储，从而避免了敏感数据的外泄。其次，云边端协同的跨域模型训练降低了模型训练的成本；在云边端计算环境中，边端侧算力有了较大的提升，在边端侧设备中直接进行模型的训练、微调、推理成为可能；开展云边端协同的跨域分布式模型训练时，可以充分利用边端侧智能算力，同时以稀疏的模型参数传输替代稠密的训练数据传输；所以云边端协同的跨域分布式模型训练可以显著的提升云边端计算环境中可用的智能算力总量，并且降低数据传输的能源开销[39]。最后，云边端协同的跨域模型训练有利于提升模型的准确率；在云边端计算环境中，不同边端侧的数据特征分布不尽相同，例如照片中的噪点、音频中的风声等，这些干扰会显著降低模型性能；因此，在不同的边端设备中运行同一个模型时，会出现准确率下降的问题；所以，在不同的边端侧设备中，使用不同分布的数据训练、微调基础模型进行持续的学习，可以明显提升模型在不同场景下的准确率[40, 41]。

云边端协同的跨域分布式模型训练具有鲜明的环境特点。在云边端协同的跨域分布式模型训练场景下，模型训练任务运行于动态、异构的跨域节点中，呈现出云边端跨域节点之间的通信成本高、云边端跨域并行训练环境动态性强的新特征。

① 云边端跨域节点之间的通信成本高

在云计算中心进行模型的集中化训练时，数据中心通常会使用 RDMA[44, 45]、NVLink[46]、CXL[47]等高速互联手段，以提升模型的分布式训练速度。但是，在云边端协同的跨域分布式模型训练场景下，各个节点可能使用 4G、5G、Wi-Fi、以太网等无线或传统的互联方式，在通信带宽和通信延迟方面都无法与数据中心内的高速网络相提并论。具体来说，NVLink 目前的双向互联带宽为 1.8TB/s，NVLink Switch 支持 14.4TB/s 的无阻塞交换能力[46]；但是云边端计算环境中常见的万兆以太网仅能做到 10Gbit/s，约合 1.25GB/s 的互联速度[48]。

② 云边端跨域并行训练环境动态性强

在云计算中心进行模型的集中化训练时，数据中心的计算硬件、存储硬件和网络拓扑相对固定，有经验的开发人员可以很轻易的设计出高效的并行方式。但

是，在云边端协同的跨域分布式训练场景下，设备间的互联带宽会发生改变，固定的分布式模型训练通信拓扑难以适应这种情况，需要动态地改变通信的调度与通信的拓扑。

云边端协同的跨域分布式计算训练场景对跨域分布式训练通信策略的设计提出了新的挑战，如何设计新型的跨域分布式计算通信策略以高效满足跨域分布式训练的通信需求成为亟待解决的关键问题。通信优化策略可以实现对低效网络的屏蔽，是提升训练速度，降低训练成本的重要手段。在人工智能领域，已经涌现了众多的人工智能框架，如 PyTorch[24, 25, 50]、TensorFlow[51, 52]、PaddlePaddle[53]、MindSpore[54]、Jax[55]等。在进入大模型时代后，针对大模型训推也出现了众多的分布式计算框架，例如 DeepSpeed[56]、Megatron-LM[57, 58]、Colossal-AI[59]等；上述计算框架提供了分布式通信、分布式并行、模型压缩、推理优化等能力。这些人工智能计算框架极大的挖掘了集群中的通信潜力，缓解了通信瓶颈，提供了多样化的并行能力，极大的提升了在单机、计算中心内的计算效率和资源利用率。因此，可充分利用现有的计算框架研发成果，针对跨域分布式训练表现出的新特征，研发对应的跨域分布式通信策略，以充分支持云边端协同的跨域分布式训练场景。

然而，针对云边端协同场景研发跨域分布式通信策略，面临着诸多亟待解决的问题。在云边端协同的跨域分布式计算场景下，模型训练任务呈现出在运行于多样化异构智算硬件、云边端不同节点之间的通信成本高和并行训练环境动态性强的新特征，在网络通信等方面给跨域分布式计算框架的设计与实现带来了全新的挑战。

① 如何实现云边端跨域高效参数通信

云边端跨域参数通信对于模型训练任务至关重要，在云边端协同的分布式计算场景中，参数通信是实现模型训练和优化的关键环节。高效的参数通信可以减少模型训练的时间，提高模型训练的效率和效果。因此，如何高效的实现云边端跨域参数通信成为云边端协同的跨域分布式计算中亟待解决的关键问题。

云边端跨域高效参数通信面临着通信带宽和延迟的挑战：由于云边端节点间通信带宽有限和延迟较高，这直接影响了模型训练过程中的数据同步和梯度更新

效率。为了应对这一挑战，可以采取一些策略，比如使用梯度压缩和量化技术来减少通信量，以及设计更高效的通信协议来降低延迟。但这一般意味着采取更为激进的压缩策略。

云边端跨域高效参数通信面临着模型精度受损的挑战：在通信过程中，为了减少通信量，通常会采取量化与稀疏化的参数进行通信，但这可能会引起模型精度的损失，而在云边端场景下，更为底下的带宽将会进一步恶化由量化与稀疏化引起的精度损失。目前，已有的方法包括 ZeRO++，DGC，PowerSGD 等方法，能够有效的压缩梯度数据，但是无法在高压缩场景下仍旧保持好的模型精度。

② 如何实现云边端通信高效的优化器策略

分布式计算节点的通信速度对于模型训练任务的性能至关重要。在云边端协同的跨域分布式计算场景中，跨域节点间的通信成本较高，通信带宽和延迟都无法和数据中心内相提并论。因此，如何高效地实现云边端跨域节点快速通信成为云边端协同的跨域分布式计算中亟待解决的关键问题。

云边端高效优化器策略面临着通信带宽和延迟的挑战。在云边端协同的分布式计算中，由于节点间通信带宽有限和延迟较高，导致模型训练过程中的数据同步和梯度更新效率低下。这种带宽和延迟的限制，尤其是在无线网络环境下，成为了优化器设计中必须考虑的重要因素。为了应对这一挑战，可以采取一些策略，比如通过优化数据传输策略来减少通信量，例如使用量化技术，以及设计更高效的通信协议来降低延迟。

云边端高效优化器策略面临着模型精度损失和收敛速度慢的挑战。量化与稀疏化的梯度通信虽然可以减少通信量，但可能会引起模型精度的损失，同时由于信息的不完整性，导致模型收敛速度变慢。为了解决这些问题，可以采用一些先进的优化技术，比如使用混合精度训练，这可以在减少内存占用的同时保持模型的精度。此外，还可以采用多粒度的选择性重计算策略，根据当前显存占用情况选取最佳的重计算策略，达到计算性能和显存占用之间的平衡。还有研究提出了基于分布式强化学习的协同流量调度算法，通过实验验证了所提协同流量调度方案的有效性，这可以为优化器策略提供参考。同时，也有研究提出了跨云边端协同计算的方法，通过任务切分和协同执行，将一个任务切分成多个子任务，并

将这些子任务分配给不同的设备，最后将它们的结果合并得到最终结果，这种方法可以充分利用各节点的资源，提高处理效率。

③ 如何动态地生成云边端跨域集合通信策略

动态生成云边端跨域训练集合通信策略对于模型训练任务至关重要。在云边端协同的跨域分布式计算场景中，云边端环境动态变化，网络拓扑、连接关系、连接能力都会发生变化。因此，如何动态地生成云边端跨域集合通信策略成为云边端协同的跨域分布式计算中亟待解决的关键问题。

生成云边端跨域训练集合通信策略面临着如何设计通信拓扑策略的挑战。在云边端计算环境中，应用定制的通信拓扑进行集合通信，合理的处理不同节点间通信能力不统一，是提升跨域模型训练的有效手段。目前，现有的通信拓扑规划主要有 Tree All-Reduce、Double Binary Tree All-Reduce、Ring All-Reduce、Hierarchical Ring All-Reduce、2D-Torus 等手段，在云边端计算环境中仍处于给出固定拓扑进行通信的固定集合通信模式。然而，由于复杂的数据分布，异构的计算设备、不稳定的互联网络，在云边端计算环境中简单的利用某一拓扑通信策略或对其进行简单的组合，并不能提升云边端环境中的通信效率；需要进行全新的设计，可以针对不同的环境动态的分层使用不同的通信拓扑策略，最大化集合通信效率。

生成云边端跨域训练集合通信策略面临着如何调度通信原语的挑战。在云边端计算环境中，通信原语是实现集合通信操作的基本单元，它们包括但不限于发送（Send），接收（Receive），广播（Broadcast）、规约（Reduce）等。这些原语的调度对于确保数据在不同节点间高效传输至关重要。目前，现有的一些调度手段有动态调度策略，使得调度器优先选择对延迟更敏感的通信任务；同时包括

综上所述，云边端计算环境是未来科技和产业竞争的制高点，发展面向云边端协同的跨域分布式技术是大势所趋。在云边端计算环境中，进行跨域分布式训练表现出不同于以往模型训练的全新的特点，例如云边端跨域智能计算硬件异构性强、云边端跨域节点之间的通信成本高、云边端跨域并行训练环境动态性强等。对跨域分布式计算框架的设计和研发提出了诸多亟待解决的全新问题：1、如何充分地利用多样云边端异构计算资源；2、如何高效地实现云边端跨域节点快速

通信；3、如何动态地生成云边端跨域训练并行策略。针对上述问题和挑战，本论文拟针对性地研究跨域分布式计算框架的异构硬件训练、通信效率优化、并行策略生成等方面，形成一套针对云边端协同跨域分布式计算的计算框架，促进云边端计算环境中智能化的发展。本论文工作对突破跨域分布式计算框架核心技术，提升云边端智能化水平，促进我国相关产业发展具有重要意义。

2. 国内外研究现状

近年来，随着云边端计算环境中智能化技术的发展和演进，模型训练任务对跨域分布式计算框架在异构计算、通信优化、自动并行等方面提出了新的需求。在云边端计算环境中，模型训练任务运行于动态、异构的跨域节点中，呈现出云边端跨域智能计算硬件异构性强、云边端跨域节点之间的通信成本高、云边端跨域并行训练环境动态性强的新特征；针对这些全新的特征，国内外的学术界和工业界针对异构硬件训练、通信优化策略、动态并行策略等方面开展了广泛的研究，相关的文献综述如下：

2.1. 云边端计算环境通信优化策略相关工作

在深度学习模型的训练过程中，在多个 GPU 或节点之间同步模型参数、梯度和优化器状态，产生了巨大的通信开销，成为了模型训练的瓶颈；在云边端计算环境中，贫瘠的网络资源无疑放大了这个问题。因此，如何高效地实现云边端跨域节点快速通信成为了构建跨域分布式计算框架的一个重要问题。当前的研究主要集中在减少通信量、优化通信模式、增强计算和通信之间的重叠性等方面，下面将分别介绍相关的工作。

2.1.1. 减少通信量的相关工作

减少通信量是指在传输之前压缩梯度或模型参数，以减小数据传输的规模，减低分布式模型训练通信开销的方法，常见的减少通信量的方法有量化和稀疏化两种。

微软为了实现超大规模的模型训练，提出了 ZeRO 优化策略[71–73]。ZeRO 可以在多个 GPU 之间分配模型权重、梯度和优化器状态来实现并行计算，从而增加通信量和频率，但是却引入了巨量的通信开销；为了尽可能减小通信开销，微软基于 ZeRO 提出了 ZeRO++通信优化策略[74]。其采用权重量化，将模型参数在通信之前实时地压缩为更小的数据类型（INT8），从而减少了所需的通信带宽和时间；此外，ZeRO++在每台机器上维护完整的模型副本，增强机器内部的通信带宽。Wang 等人提出了一种混合压缩技术 CocktailSGD[75]。该技术结合随机稀

疏化、Top-K 稀疏化和参数量化等三种不同的压缩技术，巧妙地将通信与局部梯度计算重叠，在仅有 500Mbps 的以太网中实现了卓越的训练性能。Song 等人创造性的提出了一种基于压缩的 3D 并行技术 Optimus-CC[76]。该技术在数据并行的流程压缩的基础上，实现了全新的级间反向传播压缩和嵌入同步压缩，并且研发了全新的关键通信路径识别机制；在不同训练阶段，根据通信需求动态、选择性地进行压缩，从而在尽可能维持模型精度的前提下，最大程度地减少不必要的通信开销，提升整体训练效率。Yu 等人提出了一种双重量化技术以加速模型训练过程[77]。该技术首先提出了一种同时量化模型参数和梯度的通用方案，其次基于该通用方案，提出了异步地精度并行算法、梯度稀疏-双重量化、动量量化加速技术等 3 种提升通信效率的算法。Chen 等人提出了一种可拓展的稀疏化梯度压缩策略 ScaleCom[78]。该技术利用工作节点之间梯度分布的相似性提供可交换压缩器并保持通信成本与工作节点数目一致，并且使用包含局部梯度累积的低通滤波器以减轻大批量训练的影响。Hu 等人提出了一种混合梯度压缩和梯度稀疏化的混合压缩策略 HGC[79]。该技术实现了一种动态选择策略，可以在工作节点工作的过程中动态的选择采用量化或者稀疏化策略，以结合两种方法的优点，实现较高的压缩率和较好的训练效果。

现有的减少通信量的方法一般使用量化、稀疏化等两种手段作为基本方法，得到了令人惊叹的压缩比和训练的加速比，未来将会朝着特定模型优化、特定网络条件优化的方向发展。但是，现有的减少通信量的压缩方法缺乏对低带宽、高延迟网络场景的优化。

2.1.2. 优化通信模式的相关工作

优化通信模式是指在节点通信时通过优化通信库、变化通信结构、优化通信硬件等方式加速模型训练节点间通信速度的方法。

Gan 等人提出了一款 Bagua 的 MPI 风格通信库[80]。Bagua 提供了一系列既灵活又模块化通信原语，以支持基于数据并行的分布式模型训练中的最先进的“system relaxations”技术，例如量化、去中心化通信和延迟通信等；通过这种设计，Bagua 实现了对各种分布式训练机制的高效支持和扩展。Duan 等人提出了一种在传输层加速模型训练的通信调度技术 Mercury[81]。Mercury 构建了一个

简单的传输层调度器，将张量传输的优先级调度移动到传输层，以数据包为粒度完成调度；通过上述手段，Mercury 消除了张量传输调度的启动延时和超参数的快捷调整，加速模型训练速度。Chen 等人提出了一种全新的针对 LLM 训练的通信调度框架 Centauri[82]。该技术将混合并行训练中的调度任务分解为算子、模型层、模型三个层次，探索了由原始替换分区、拓扑感知组分区和工作负载分区组成的优化空间，构建了适合异构环境的新型通信调度框架。Fang 等人提出了一种适用于分布式训练的网络聚合路由 GRID[83]。GRID 在分布式训练中使用梯度路由与网络聚合，在控制平面上，使用基于随机舍入的高效梯度路由算法，在数据平面上，通过精心设计工作节点和可编程开关逻辑实现网内聚合，通过上述手段缓解了训练集群内的网络瓶颈。Lao 等人提出了一种适用于多租户学习的网络聚合策略 ATP[84]。ATP 使用新兴的可编程交换机支持集群中多个机架交换机的网络内聚合，以加速深度学习训练作业。ATP 采用分散、动态、尽力而为的聚合策略，能够在同时运行的深度学习训练作业之间高效、公平地共享有限的交换机资源，并妥善应对交换机资源的激烈争用。Liu 等人提出了路由聚合的网络聚合策略 InArt 加速模型训练[85]。InArt 是第一个在多 PS 架构中引入网内聚合和路由选择的工作，其采用多 PS 架构将模型训练任务拆分到多个 PS 之间，并选择合适的路由方案以充分利用网内聚合能力。Gebara 等人提出了一种用于共享集群机器学习工作负载的网络架构 PANAMA[86]。PANAMA 由一个高效的网络加速硬件和配套的拥塞控制协议组成，实现了大规模通信负载的卸载和不同流之间公平的网络资源共享。

现有的优化通信模式的方法一般以优化通信库、变化通信结构、优化通信硬件为主要思路，并且取得了较好的机器学习训练加速效果，未来将继续朝着定制硬件、定制网络结构优化的方向发展。在云边端计算环境中，网络通信硬件、网络种类、网络拓扑多样，现有的通信结构优化、通信硬件优化难以适用这样的场景和需求。

2.1.3. 增强计算和通信的重叠性的相关工作

增强计算和通信的重叠性是指通过通信拆分、通信调度、异步传输等手段使得深度学习训练过程中通信与计算充分重叠的手段。

Wang 等人面向层内并行时通过规模过大的问题，提出了一种全新的通信-计算分解技术[87]。此技术可以识别原始的通信集合与相关的计算操作，并将它们协同分解为一系列更细粒度的操作，以创造更多的重叠机会；并且此技术可以并行执行新创建的、更细粒度的通信和计算操作，从而有效地实现了计算和数据的重叠，隐藏了数据传输延迟，并实现了更好的系统利用率。Feng 等人提出了一种用于异构内存的流水线策略 Mobius[88]。该策略将模型划分规约成一个整数规划问题，以实现更细粒度的模型划分；该策略在 GPU 和 DRAM 之间进行模型划分的细粒度调度，将数据从 CPU 预取到 GPU 内存以进行下一阶段的计算，充分的实现通信和计算的重叠；此外，它还采用交叉映射策略来减少通信争用，进一步优化整体性能。Oh 等人提出了一种乱序反向传播技术 Out-Of-Order BackProp[89]。该技术针对单 GPU 训练、数据并行、流水线并行分别通过多流调度、梯度重排序、关键梯度识别三项技术，优化计算输出梯度、权重梯度和参数更新的顺序，最大化了通信和计算之间的重叠。Li 等人提出了一种全新的使用了 3D 并行的通信管到 Fold3D[90]。Fold3D 提出了用于 3D 并行的 AIAO 调度，该调度将一个深度学习模型切分成多个段，以统一调度处理同一深度学习模型的段计算任务，并且启动该段的通信任务的同步，以与其他段的计算任务重叠。Lai 等人提出了一种自动 3D 并行优化和通信技术 Merak[91]。该技术通过自动模型分区实现 3D 并行的自动部署，另外还集成了转移关键路径管道调度、空闲内存感知的重计算以实现计算和通信的重叠。Zhang 等人提出了一种内存友好的 MoE 模型流水线并行技术 MPMoE[92]。该技术可通过自适应和内存高效的流水线并行性加速 MoE 训练，并将 MoE 的训练过程分为多个独立子阶段，设计了全新的计算-通信重叠减少通信延迟。

现有的增强计算和通信重叠性的手段主要是通过通信拆分、通信调度、异步传输、结合流水线并行等手段实现的，取得了较好的加速效果，未来将朝着更加细粒度的通信调度、与 3D 并行结合优化的方向进行发展。在云边端计算环境中，网络情况相对恶劣，且缺乏成熟的并行策略，如何增强计算和通信的并行性还有较大的探索和优化空间。

综上所述，对于云边端计算环境中的通信优化，现有的减小通信规模、优化

通信模式、增强计算和通信的重叠性的方案，难以适应云边端计算环境复杂的网络特征。具体来说，现有的减少通信量的压缩方法缺乏对低带宽、高延迟网络场景的优化；现有的通信结构优化、通信硬件优化难以适用网络通信硬件、网络种类、网络拓扑多样的场景和需求；现有的增强计算和通信并行性的方法缺少贫瘠网络条件与云边端并行策略的结合。这些问题都导致现有的通信优化策略难以发挥其优化能力，限制了其在云边端计算环境中的性能收益。因此，研究一种适合云边端计算环境的通信优化策略是极为重要的，如何高效地实现云边端跨域节点快速通信成为亟待解决的问题。

3. 研究现状总结与分析

通过充分、深入地调查研究现有云边端计算环境中跨域分布式训练的相关工作，可以总结如下结论：

3.1. 论文研究领域存在的问题

在云边端计算环境中，跨域分布式训练面临着下面 3 个方面的挑战：1、如何充分地利用多样云边端异构计算资源；2、如何高效地实现云边端跨域节点快速通信；3、如何动态地生成云边端跨域训练并行策略。详细分析如下：

3.1.1. 如何实现云边端跨域高效参数通信

云边端跨域参数通信对于模型训练任务至关重要，在云边端协同的分布式计算场景中，参数通信是实现模型训练和优化的关键环节。高效的参数通信可以减少模型训练的时间，提高模型训练的效率和效果。因此，如何高效的实现云边端跨域参数通信成为云边端协同的跨域分布式计算中亟待解决的关键问题。

云边端跨域高效参数通信面临着通信带宽和延迟的挑战：由于云边端节点间通信带宽有限和延迟较高，这直接影响了模型训练过程中的数据同步和梯度更新效率。为了应对这一挑战，可以采取一些策略，比如使用梯度压缩和量化技术来减少通信量，以及设计更高效的通信协议来降低延迟。但这一般意味着采取更为激进的压缩策略。

云边端跨域高效参数通信面临着模型精度受损的挑战：在通信过程中，为了

减少通信量，通常会采取量化与稀疏化的参数进行通信，但这可能会引起模型精度的损失，而在云边端场景下，更为底下的带宽将会进一步恶化由量化与稀疏化引起的精度损失。目前，已有的方法包括 ZeRO++，DGC，PowerSGD 等方法，能够有效的压缩梯度数据，但是无法在高压缩场景下仍旧保持好的模型精度。

3.1.2. 如何实现云边端通信高效的优化器策略

分布式计算节点的通信速度对于模型训练任务的性能至关重要。在云边端协同的跨域分布式计算场景中，跨域节点间的通信成本较高，通信带宽和延迟都无法和数据中心内相提并论。因此，如何高效地实现云边端跨域节点快速通信成为云边端协同的跨域分布式计算中亟待解决的关键问题。

云边端高效优化器策略面临着通信带宽和延迟的挑战。在云边端协同的分布式计算中，由于节点间通信带宽有限和延迟较高，导致模型训练过程中的数据同步和梯度更新效率低下。这种带宽和延迟的限制，尤其是在无线网络环境下，成为了优化器设计中必须考虑的重要因素。为了应对这一挑战，可以采取一些策略，比如通过优化数据传输策略来减少通信量，例如使用量化技术，以及设计更高效的通信协议来降低延迟。

云边端高效优化器策略面临着模型精度损失和收敛速度慢的挑战。量化与稀疏化的梯度通信虽然可以减少通信量，但可能会引起模型精度的损失，同时由于信息的不完整性，导致模型收敛速度变慢。为了解决这些问题，可以采用一些先进的优化技术，比如使用混合精度训练，这可以在减少内存占用的同时保持模型的精度。此外，还可以采用多粒度的选择性重计算策略，根据当前显存占用情况选取最佳的重计算策略，达到计算性能和显存占用之间的平衡。还有研究提出了基于分布式强化学习的协同流量调度算法，通过实验验证了所提协同流量调度方案的有效性，这可以为优化器策略提供参考。同时，也有研究提出了跨云边端协同计算的方法，通过任务切分和协同执行，将一个任务切分成多个子任务，并将这些子任务分配给不同的设备，最后将它们的结果合并得到最终结果，这种方法可以充分利用各节点的资源，提高处理效率。

3.1.3. 如何动态地生成云边端跨域训练并行策略

动态生成云边端跨域训练集合通信策略对于模型训练任务至关重要。在云边端协同的跨域分布式计算场景中，云边端环境动态变化，网络拓扑、连接关系、连接能力都会发生变化。因此，如何动态地生成云边端跨域集合通信策略成为云边端协同的跨域分布式计算中亟待解决的关键问题。

生成云边端跨域训练集合通信策略面临着如何设计通信拓扑策略的挑战。在云边端计算环境中，应用定制的通信拓扑进行集合通信，合理的处理不同节点间通信能力不统一，是提升跨域模型训练的有效手段。目前，现有的通信拓扑规划主要有 Tree All-Reduce、Double Binary Tree All-Reduce、Ring All-Reduce、Hierarchical Ring All-Reduce、2D-Torus 等手段，在云边端计算环境中仍处于给出固定拓扑进行通信的固定集合通信模式。然而，由于复杂的数据分布，异构的计算设备、不稳定的互联网络，在云边端计算环境中简单的利用某一拓扑通信策略或对其进行简单的组合，并不能提升云边端环境中的通信效率；需要进行全新的设计，可以针对不同的环境动态的分层使用不同的通信拓扑策略，最大化集合通信效率。

生成云边端跨域训练集合通信策略面临着如何调度通信原语的挑战。在云边端计算环境中，通信原语是实现集合通信操作的基本单元，它们包括但不限于发送（Send），接收（Receive），广播（Broadcast）、规约（Reduce）等。这些原语的调度对于确保数据在不同节点间高效传输至关重要。目前，现有的一些调度手段有动态调度策略，使得调度器优先选择对延迟更敏感的通信任务；同时包括

3.2. 论文研究领域的发展趋势

协同利用云边端异构计算资源进行模型训练的技术将会蓬勃发展。对于云边端计算环境中的异构硬件训练，现有主要有充分利用单节点资源和协同多个异构节点进行模型运行两种思路，但是目前大多针对模型异构推理场景，异构训练的相关研究近年来初步涌现。具体来说，现有的优化单设备模型运行主要使用稀疏化、编译、转换等手段使得模型可以在 CPU、GPU、DSP 等异构设备中运行，目前可实现在边端异构设备中实现模型的运行，奠定了良好的基础；现有的协同

多异构节点联合运行模型主要集中在异构节点建模、通过并行策略综合利用异构计算资源两个方面，且模型协同推理技术相对成熟，协同训练技术初步崭露头角，计算效率、异构资源利用率都比较低，远未成熟。总得来说，现有的云边端计算环境中的异构硬件协同训练技术还远未成熟，面临着计算效率低下、异构资源利用率低下的问题，限制了云边端计算环境中综合利用异构硬件进行模型训练的效率。因此，研究一种适合云边端计算环境的异构硬件训练策略是极为重要的。

云边端计算环境中计算-通信模式发生变化需要全新的通信优化手段。对于云边端计算环境中的通信优化，现有的减小通信规模、优化通信模式、增强计算和通信的重叠性的方案，难以适应云边端计算环境复杂的网络特征。具体来说，现有的减少通信量的压缩方法缺乏对低带宽、高延迟网络场景的优化；现有的通信结构优化、通信硬件优化难以适用网络通信硬件、网络种类、网络拓扑多样的场景和需求；现有的增强计算和通信并行性的方法缺少贫瘠网络条件与云边端并行策略的结合。这些问题都导致现有的通信优化策略难以发挥其优化能力，限制了其在云边端计算环境中的性能收益。因此，研究一种适合云边端计算环境的通信优化策略是极为重要的。

综上所述，围绕分布式计算框架，业内在异构硬件训练、通信优化策略、动态并行策略等方面开展了大量的研究和探索。然而，对于云边端协同的跨域分布式计算场景中呈现出的运行于多样化异构智算硬件、云边端不同节点之间的通信成本高和手动规划并行策略困难等新特征，现有方法仍然难以有效应对。

3.3. 研究现状分析结论

经过上述的讨论和分析，结论如下：

1、需要研究一种可以合理进行分布式训练模型量化与稀疏压缩的机制，实现高压缩率下仍维持较高准确性的模型训练，以提升云边端分布式训练的训练速度，保证模型精度。

2、需要研究一种可以应对高压缩场景下的模型更新优化器方法，实现在云边端环境中通信高效的，收敛性好的，训练效率高的分布式训练。

3、需要研究一种可以处理云边端场景中节点间进行集合通信能力差的集合通信拓扑构建与通信调度方法，实现在网络恶劣条件下的高效集合通信。

主要参考文献

[1] Office of Science and Technology Policy. National Strategic Computing Initiative Update[EB]. 2019

[2] Office of Science and Technology Policy. Pioneering the Future Advanced Computing Ecosystem: A Strategic Plan[EB]. 2020

[3] DEPARTMENT OF DEFENSE. 5G Strategy Implementation Plan[EB]. 2020

[4] Office of Science and Technology Policy. Critical and Emerging Technologies List[EB]. 2024

[5] Home | European Citizens' Initiative[EB/OL]. https://citizens-initiative.europa.eu/_en, 2024-08-02

[6] European Commission. Horizon Europe Work Programme 2021-2022[EB]. 2022

[7] IPCEI - European Commission[EB/OL]. https://competition-policy.ec.europa.eu/state-aid/ipcei_en, 2024-08-02

[8] 习近平：高举中国特色社会主义伟大旗帜 为全面建设社会主义现代化国家而团结奋斗——在中国共产党第二十次全国代表大会上的报告_共产党员网[EB/OL]. https://www.12371.cn/2022/10/25/ARTI1666705047474465.shtml, 2024-08-02

[9] "十四五"数字经济发展规划[EB]. 2021

[10] 中共中央 国务院印发《数字中国建设整体布局规划》_最新政策_中国政府网[EB/OL]. https://www.gov.cn/zhengce/2023-02/27/content_5743484.htm, 2024-08-02

[11] 朱豫. 工业和信息化部关于印发《新型数据中心发展三年行动计划（2021-2023 年）》的通知_国务院部门文件_中国政府网[EB/OL]. https://www.gov.cn/zhengce/zhengceku/2021-07/14/content_5624964.htm, 2024-08-02

[12] Azure Public Multi-Access Edge Compute (MEC) | Microsoft Azure[EB/OL]. https://azure.microsoft.com/en-gb/solutions/public-multi-access-edge-compute-mec, 2024-08-02

[13] 适合于边缘站点的 AWS – 边缘计算和存储、5G、混合环境、物联网 - Amazon Web Services[EB/OL]. https://aws.amazon.com/cn/edge/, 2024-08-02

[14] Deploy O. Continuous Delivery & Deployment Automation Tool for DevOps Teams[EB/OL]. https://octopus.com, 2024-08-02

[15] AWS 上的 Volkswagen Group：案例研究、视频。创客案例[EB/OL]. http

s://aws.amazon.com/cn/solutions/case-studies/innovators/volkswagen-group/, 2024-08-02

[16] iRobot 和 AWS IoT 轻松应对每年的流量高峰时段 | 视频 | AWS[EB/OL]. https://aws.amazon.com/cn/solutions/case-studies/irobot-iot/, 2024-08-02

[17] Amazon Web Services. Reinventing Cloud Native 5G Networks with AWS and DISH[EB]. 2021

[18] KubeEdge[EB/OL]. https://kubeedge.io/, 2024-08-02

[19] SuperEdge[EB/OL]. https://superedge.io/, 2024-08-02

[20] An open platform that extends upstream Kubernetes to Edge | OpenYurt [EB/OL]. https://openyurt.io/zh/, 2024-08-02

[21] 肖利民, 宋尧, 秦广军, et al. GVDS：面向广域高性能计算环境的虚拟数据空间[J]. 大数据, 2021,7(2): 123-146

[22] IDC：人工智能算力向边缘侧迁移，将带动中国边缘服务器稳步增长[EB/OL]. https://www.idc.com/getdoc.jsp?containerId=prCHC52069324, 2024-08-02

[23] IDC：5G 和人工智能技术推动中国边缘服务器市场逆势增长[EB/OL]. https://www.idc.com/getdoc.jsp?containerId=prCHC50867923, 2024-08-02

[24] PyTorch Edge[EB/OL]. https://pytorch.org/edge, 2024-08-02

[25] PyTorch[EB/OL]. https://pytorch.org/, 2024-08-02

[26] Chen T., Moreau T., Jiang Z., et al. TVM: An Automated End-to-End Optimizing Compiler for Deep Learning[J]

[27] Apache TVM[EB/OL]. https://tvm.apache.org/, 2024-08-02

[28] TensorFlow Lite | TensorFlow 中文官网[EB/OL]. https://www.tensorflow.org/lite?hl=zh-cn, 2024-08-02

[29] NVIDIA Embedded Systems for Next-Gen Autonomous Machines[EB/OL]. https://www.nvidia.com/en-us/autonomous-machines/embedded-systems/, 2024-08-02

[30] NVIDIA Jetson AGX Orin[EB/OL]. https://www.nvidia.com/en-us/autonomous-machines/embedded-systems/jetson-orin/, 2024-08-02

[31] NVIDIA TensorRT[EB/OL]. https://developer.nvidia.com/tensorrt, 2024-08-02

[32] AMD Ryzen™ AI - Windows PCs with AI Built In[EB/OL]. https://www.amd.com/en/products/processors/consumer/ryzen-ai.html, 2024-08-02

[33] AMD ROCm™ Software[EB/OL]. https://www.amd.com/en/products/software/rocm.html, 2024-08-02

[34] 天数智芯[EB/OL]. https://www.iluvatar.com/productDetails?fullCode=cpjs-yj-tlxltt-zk100, 2024-08-02

[35] MLU270-S4 智能加速卡 - 寒武纪[EB/OL]. https://www.cambricon.com/index.php?m=content&c=index&a=lists&catid=36, 2024-08-02

[36] 曦思 N 系列产品-产品与解决方案[EB/OL]. https://www.metax-tech.com/prod.html?cid=1, 2024-08-02

[37] Atlas 300I-推理卡-AI 加速卡-华为企业业务[EB/OL]. https://e.huawei.com/cn/products/computing/ascend/atlas-300-ai, 2024-08-02

[38] Yu J., Prabhu K., Urman Y., et al. 8-Bit Transformer Inference and Fine-Tuning for Edge Accelerators[A]. Proceedings of the 29th ACM International Conference on Architectural Support for Programming Languages and Operating Systems, Volume 3[C]. La Jolla CA USA: ACM, 2024: 5-21

[39] Choudhury A., Wang Y., Pelkonen T., et al. MAST: Global Scheduling of ML Training across Geo-Distributed Datacenters at Hyperscale[J]

[40] Kirkpatrick J., Pascanu R., Rabinowitz N., et al. Overcoming Catastrophic Forgetting in Neural Networks[J]. Proceedings of the National Academy of Sciences, 2017,114(13): 3521-3526

[41] Gong T., Kim Y., Shin J., et al. MetaSense: Few-Shot Adaptation to Untrained Conditions in Deep Mobile Sensing[A]. Proceedings of the 17th Conference on Embedded Networked Sensor Systems[C]. New York, NY, USA: Association for Computing Machinery, 2019: 110-123

[42] Zhu L., Hu L., Lin J., et al. PockEngine: Sparse and Efficient Fine-Tuning in a Pocket[A]. 56th Annual IEEE/ACM International Symposium on Microarchitecture[C]. Toronto ON Canada: ACM, 2023: 1381-1394

[43] NVIDIA A100 GPU 为现代数据中心注入强大动力[EB/OL]. https://www.nvidia.cn/data-center/a100/, 2024-08-03

[44] GPUDirect RDMA[EB/OL]. https://docs.nvidia.com/cuda/gpudirect-rdma/, 2024-08-03

[45] K R. InfiniBand Trade Association[EB/OL]. https://www.infinibandta.org/, 2024-08-03

[46] NVLink & NVSwitch for Advanced Multi-GPU Communication[EB/OL]. https://www.nvidia.com/en-us/data-center/nvlink/, 2024-08-03

[47] Homepage - Compute Express Link[EB/OL]. https://computeexpresslink.org/, 2023-09-19/2024-08-03

[48] 10 Gigabit Ethernet - Wikipedia[EB/OL]. https://en.wikipedia.org/wiki/10_Gigabit_Ethernet, 2024-08-03

[49] Liang P., Tang Y., Zhang X., et al. A Survey on Auto-Parallelism of Large-Scale Deep Learning Training[J]. IEEE Transactions on Parallel and Distributed Systems, 2023,34(8): 2377-2390

[50] Paszke A., Gross S., Massa F., et al. PyTorch: An Imperative Style, High-Performance Deep Learning Library[A]. Advances in Neural Information Processing Systems: Vol. 32[C]. Curran Associates, Inc., 2019

[51] 关于 TensorFlow | TensorFlow 中文官网[EB/OL]. https://www.tensorflow.org/?hl=zh-cn, 2024-08-06

[52] Abadi M., Agarwal A., Barham P., et al. TensorFlow: Large-Scale Machine Learning on Heterogeneous Distributed Systems[EB]. arXiv, 2016

[53] PaddlePaddle/Paddle: PArallel Distributed Deep LEarning: Machine Learning Framework from Industrial Practice （『飞桨』核心框架，深度学习&机器学习高性能单机、分布式训练和跨平台部署）[EB/OL]. https://github.com/PaddlePaddle/Paddle, 2024-08-06

[54] Mindspore-Ai/Mindspore: MindSpore Is a New Open Source Deep Learning Training/Inference Framework That Could Be Used for Mobile, Edge and Cloud Scenarios.[EB/OL]. https://github.com/mindspore-ai/mindspore, 2024-08-06

[55] Google/Jax: Composable Transformations of Python+NumPy Programs: Differentiate, Vectorize, JIT to GPU/TPU, and More[EB/OL]. https://github.com/google/jax, 2024-08-06

[56] Microsoft/DeepSpeed: DeepSpeed Is a Deep Learning Optimization Library That Makes Distributed Training and Inference Easy, Efficient, and Effective.[EB/OL]. https://github.com/microsoft/DeepSpeed, 2024-08-06

[57] NVIDIA/Megatron-LM: Ongoing Research Training Transformer Models at Scale[EB/OL]. https://github.com/NVIDIA/Megatron-LM, 2024-08-06

[58] Shoeybi M., Patwary M., Puri R., et al. Megatron-LM: Training Multi-Billion Parameter Language Models Using Model Parallelism[EB]. arXiv, 2020

[59] Hpcaitech/ColossalAI: Making Large AI Models Cheaper, Faster and More Accessible[EB/OL]. https://github.com/hpcaitech/ColossalAI, 2024-08-06

[60] Jiang X., Wang H., Chen Y., et al. MNN: A Universal and Efficient Inference Engine[EB/OL]. https://arxiv.org/abs/2002.12418v1, 2020-02-27/2024-08

-12

[61] Patil S. G., Jain P., Dutta P., et al. POET: Training Neural Networks on Tiny Devices with Integrated Rematerialization and Paging[A]. Proceedings of the 39th International Conference on Machine Learning[C]. PMLR, 2022: 17573-17583

[62] Wang S., Feng T., Yang H., et al. AtRec: Accelerating Recommendation Model Training on CPUs[J]. IEEE Transactions on Parallel and Distributed Systems, 2024,35(6): 905-918

[63] Zhang L., Lu K., Lai Z., et al. Accelerating GNN Training by Adapting Large Graphs to Distributed Heterogeneous Architectures[J]. IEEE Transactio ns on Computers, 2023,72(12): 3473-3488

[64] Zhang D., Huang X., Liu Z., et al. AGL: A Scalable System for Industri al-Purpose Graph Machine Learning[J]. Proc. VLDB Endow., 2020,13(12): 3 125-3137

[65] Mao J., Chen X., Nixon K. W., et al. MoDNN: Local Distributed Mobil e Computing System for Deep Neural Network[A]. Design, Automation & Test in Europe Conference & Exhibition (DATE), 2017[C]. Lausanne, Switz erland: IEEE, 2017: 1396-1401

[66] Zeng L., Chen X., Zhou Z., et al. CoEdge: Cooperative DNN Inference With Adaptive Workload Partitioning Over Heterogeneous Edge Devices[J]. IEEE/ACM Transactions on Networking, 2021,29(2): 595-608

[67] Zhao Z., Barijough K. M., Gerstlauer A. DeepThings: Distributed Adapti ve Deep Learning Inference on Resource-Constrained IoT Edge Clusters[J]. IEEE Transactions on Computer-Aided Design of Integrated Circuits and Sy stems, 2018,37(11): 2348-2359

[68] Hao P., Zhang Y. EDDL: A Distributed Deep Learning System for Resou rce-Limited Edge Computing Environment[A]. 2021 IEEE/ACM Symposium on Edge Computing (SEC)[C]. 2021: 1-13

[69] Yang L., Gan Y., Chen J., et al. AutoSF: Adaptive Distributed Model Tr aining in Dynamic Edge Computing[J]. IEEE Transactions on Mobile Comp uting, 2024,23(6): 6549-6562

[70] Chen Y., Yang Q., He S., et al. FTPipeHD: A Fault-Tolerant Pipeline-Par allel Distributed Training Approach for Heterogeneous Edge Devices[J]. IEE E Transactions on Mobile Computing, 2024,23(4): 3200-3212

[71] Rajbhandari S., Rasley J., Ruwase O., et al. ZeRO: Memory Optimizatio ns toward Training Trillion Parameter Models[A]. Proceedings of the Interna tional Conference for High Performance Computing, Networking, Storage an d Analysis[C]. Atlanta, Georgia: IEEE Press, 2020: 1-16

[72] Ren J., Rajbhandari S., Aminabadi R. Y., et al. ZeRO-Offload: Democrati zing Billion-Scale Model Training[EB]. arXiv, 2021

[73] Rajbhandari S., Ruwase O., Rasley J., et al. ZeRO-Infinity: Breaking the GPU Memory Wall for Extreme Scale Deep Learning[A]. Proceedings of th e International Conference for High Performance Computing, Networking, St orage and Analysis[C]. St. Louis Missouri: ACM, 2021: 1-14

[74] Wang G., Qin H., Jacobs S. A., et al. ZeRO++: Extremely Efficient Coll ective Communication for Giant Model Training[EB]. arXiv, 2023

[75] Wang J., Lu Y., Yuan B., et al. CocktailSGD: Fine-Tuning Foundation M odels over 500mbps Networks[A]. Proceedings of the 40th International Con ference on Machine Learning: Vol. 202[C]. Honolulu, Hawaii, USA: JMLR. org, 2023: 36058-36076

[76] Song J., Yim J., Jung J., et al. Optimus-CC: Efficient Large NLP Model Training with 3D Parallelism Aware Communication Compression[A]. Proc eedings of the 28th ACM International Conference on Architectural Support for Programming Languages and Operating Systems, Volume 2[C]. Vancouv er BC Canada: ACM, 2023: 560-573

[77] Yu Y., Wu J., Huang L. Double Quantization for Communication-Efficien t Distributed Optimization[A]. Advances in Neural Information Processing S ystems: Vol. 32[C]. Curran Associates, Inc., 2019

[78] Chen C.-Y., Ni J., Lu S., et al. ScaleCom: Scalable Sparsified Gradient Compression for Communication-Efficient Distributed Training[A]. Advances in Neural Information Processing Systems: Vol. 33[C]. Curran Associates, In c., 2020: 13551-13563

[79] Hu K., Wu C., Zhu E. HGC: Hybrid Gradient Compression in Distribute d Deep Learning[A]. Sun X., Zhang X., Xia Z., et al. Advances in Artifici al Intelligence and Security[C]. Cham: Springer International Publishing, 202 1: 15-27

[80] Gan S., Jiang J., Yuan B., et al. Bagua: Scaling up Distributed Learning with System Relaxations[J]. Proc. VLDB Endow., 2021,15(4): 804-813

[81] Duan Q., Peng C., Wang Z., et al. Accelerating Distributed DNN Training via Transport Layer Scheduling[J]. IEEE Transactions on Parallel and Distributed Systems, 2023,34(5): 1650-1666

[82] Chen C., Li X., Zhu Q., et al. Centauri: Enabling Efficient Scheduling for Communication-Computation Overlap in Large Model Training via Communication Partitioning[A]. Proceedings of the 29th ACM International Conference on Architectural Support for Programming Languages and Operating Systems, Volume 3[C]. La Jolla CA USA: ACM, 2024: 178-191

[83] Fang J., Zhao G., Xu H., et al. GRID: Gradient Routing With In-Network Aggregation for Distributed Training[J]. IEEE/ACM Transactions on Networking, 2023,31(5): 2267-2280

[84] Lao C., Le Y., Mahajan K., et al. {ATP}: In-Network Aggregation for Multi-Tenant Learning[A]. 18th USENIX Symposium on Networked Systems Design and Implementation (NSDI 21)[C]. 2021: 741-761

[85] Liu J., Zhai Y., Zhao G., et al. InArt: In-Network Aggregation with Route Selection for Accelerating Distributed Training[A]. Proceedings of the ACM on Web Conference 2024[C]. Singapore Singapore: ACM, 2024: 2879-2889

[86] Gebara N., Ghobadi M., Costa P. In-Network Aggregation for Shared Machine Learning Clusters[J]. Proceedings of Machine Learning and Systems, 2021,3: 829-844

[87] Wang S., Wei J., Sabne A., et al. Overlap Communication with Dependent Computation via Decomposition in Large Deep Learning Models[A]. Proceedings of the 28th ACM International Conference on Architectural Support for Programming Languages and Operating Systems, Volume 1[C]. New York, NY, USA: Association for Computing Machinery, 2022: 93-106

[88] Feng Y., Xie M., Tian Z., et al. Mobius: Fine Tuning Large-Scale Models on Commodity GPU Servers[A]. Proceedings of the 28th ACM International Conference on Architectural Support for Programming Languages and Operating Systems, Volume 2[C]. Vancouver BC Canada: ACM, 2023: 489-501

[89] Oh H., Lee J., Kim H., et al. Out-of-Order Backprop: An Effective Scheduling Technique for Deep Learning[A]. Proceedings of the Seventeenth European Conference on Computer Systems[C]. New York, NY, USA: Associati

on for Computing Machinery, 2022: 435-452

[90] Li F., Zhao S., Qing Y., et al. Fold3D: Rethinking and Parallelizing Com putational and Communicational Tasks in the Training of Large DNN Mode ls[J]. IEEE Transactions on Parallel and Distributed Systems, 2023,34(5): 14 32-1449

[91] Lai Z., Li S., Tang X., et al. Merak: An Efficient Distributed DNN Trai ning Framework With Automated 3D Parallelism for Giant Foundation Mod els[J]. IEEE Transactions on Parallel and Distributed Systems, 2023,34(5): 1 466-1478

[92] Zhang Z., Xia Y., Wang H., et al. MPMoE: Memory Efficient MoE for Pre-Trained Models With Adaptive Pipeline Parallelism[J]. IEEE Transaction s on Parallel and Distributed Systems, 2024,35(6): 998-1011

[93] Li S., Zhao Y., Varma R., et al. PyTorch Distributed: Experiences on Ac celerating Data Parallel Training[J]. Proceedings of the VLDB Endowment, 2020,13(12): 3005-3018

[94] Xu Y., Lee H., Chen D., et al. Automatic Cross-Replica Sharding of Wei ght Update in Data-Parallel Training[J]. ArXiv, 2020

[95] Zhao Y., Gu A., Varma R., et al. PyTorch FSDP: Experiences on Scaling Fully Sharded Data Parallel[J]. Proceedings of the VLDB Endowment, 202 3,16(12): 3848-3860

[96] Xu Q., You Y. An Efficient 2D Method for Training Super-Large Deep Learning Models[A]. 2023 IEEE International Parallel and Distributed Proce ssing Symposium (IPDPS)[C]. 2023: 222-232

[97] Wang B., Xu Q., Bian Z., et al. Tesseract: Parallelize the Tensor Parallel ism Efficiently[A]. Proceedings of the 51st International Conference on Para llel Processing[C]. New York, NY, USA: Association for Computing Machin ery, 2023: 1-11

[98] Bian Z., Xu Q., Wang B., et al. Maximizing Parallelism in Distributed T raining for Huge Neural Networks[EB]. arXiv, 2021

[99] Liu Z., Cheng S., Zhou H., et al. Hanayo: Harnessing Wave-like Pipeline Parallelism for Enhanced Large Model Training Efficiency[A]. Proceeding s of the International Conference for High Performance Computing, Networ king, Storage and Analysis[C]. New York, NY, USA: Association for Comp uting Machinery, 2023: 1-13

[100] Zhang W., Zhou B., Tang X., et al. MixPipe: Efficient Bidirectional Pipe line Parallelism for Training Large-Scale Models[A]. 2023 60th ACM/IEEE Design Automation Conference (DAC)[C]. 2023: 1-6

[101] Chen Z., Xu C., Qian W., et al. Elastic Averaging for Efficient Pipelined DNN Training[A]. Proceedings of the 28th ACM SIGPLAN Annual Symp osium on Principles and Practice of Parallel Programming[C]. New York, N Y, USA: Association for Computing Machinery, 2023: 380-391

[102] Kim T., Kim H., Yu G.-I., et al. BPipe: Memory-Balanced Pipeline Paral lelism for Training Large Language Models[A]. Proceedings of the 40th Int ernational Conference on Machine Learning[C]. PMLR, 2023: 16639-16653

[103] Thorpe J., Zhao P., Eyolfson J., et al. Bamboo: Making Preemptible Inst ances Resilient for Affordable Training of Large DNNs[J]

[104] Jiang C., Jia Z., Zheng S., et al. DynaPipe: Optimizing Multi-Task Traini ng through Dynamic Pipelines[A]. Proceedings of the Nineteenth European Conference on Computer Systems[C]. Athens Greece: ACM, 2024: 542-559

[105] He J., Zhai J., Antunes T., et al. FasterMoE: Modeling and Optimizing Training of Large-Scale Dynamic Pre-Trained Models[A]. Proceedings of the 27th ACM SIGPLAN Symposium on Principles and Practice of Parallel Pr ogramming[C]. New York, NY, USA: Association for Computing Machinery, 2022: 120-134

[106] Li J., Jiang Y., Zhu Y., et al. Accelerating Distributed {MoE} Training a nd Inference with Lina[A]. 2023 USENIX Annual Technical Conference (U SENIX ATC 23)[C]. 2023: 945-959

[107] Liu J., Wang J. H., Jiang Y. Janus: A Unified Distributed Training Fram ework for Sparse Mixture-of-Experts Models[A]. Proceedings of the ACM S IGCOMM 2023 Conference[C]. New York NY USA: ACM, 2023: 486-498

[108] Zhai M., He J., Ma Z., et al. {SmartMoE}: Efficiently Training {Sparsel y-Activated} Models through Combining Offline and Online Parallelization [A]. 2023 USENIX Annual Technical Conference (USENIX ATC 23)[C]. 20 23: 961-975

[109] Zheng L., Li Z., Zhang H., et al. Alpa: Automating Inter- and {Intra-Op erator} Parallelism for Distributed Deep Learning[A]. 16th USENIX Sympos ium on Operating Systems Design and Implementation (OSDI 22)[C]. 2022: 559-578

[110] Smith S., Patwary M., Norick B., et al. Using DeepSpeed and Megatron to Train Megatron-Turing NLG 530B, A Large-Scale Generative Language Model[EB]. arXiv, 2022

[111] Miao X., Wang Y., Jiang Y., et al. Galvatron: Efficient Transformer Training over Multiple GPUs Using Automatic Parallelism[J]. Proceedings of the VLDB Endowment, 2022,16(3): 470-479

[112] Bringing HPC Techniques to Deep Learning[R]. Baidu Tech, 2017

[113] van de Geijn R. A., Watts J. SUMMA: Scalable Universal Matrix Multiplication Algorithm[R]. USA: University of Texas at Austin, 1995

[114] Solomonik E., Demmel J. Communication-Optimal Parallel 2.5D Matrix Multiplication and LU Factorization Algorithms[A]. Proceedings of the 17th international conference on Parallel processing - Volume Part II[C]. Berlin, Heidelberg: Springer-Verlag, 2011: 90-109

[115] Li M. Scaling Distributed Machine Learning with the Parameter Server [A]. Proceedings of the 2014 International Conference on Big Data Science and Computing[C]. Beijing China: ACM, 2014: 1-1

[116] Wang M., Huang C., Li J. Supporting Very Large Models Using Automatic Dataflow Graph Partitioning[A]. Proceedings of the Fourteenth EuroSys Conference 2019[C]. New York, NY, USA: Association for Computing Machinery, 2019: 1-17

[117] Cai Z., Yan X., Ma K., et al. TensorOpt: Exploring the Tradeoffs in Distributed DNN Training With Auto-Parallelism[J]. IEEE Transactions on Parallel and Distributed Systems, 2022,33(8): 1967-1981

[118] Narayanan D., Harlap A., Phanishayee A., et al. PipeDream: Generalized Pipeline Parallelism for DNN Training[A]. Proceedings of the 27th ACM Symposium on Operating Systems Principles[C]. New York, NY, USA: Association for Computing Machinery, 2019: 1-15

[119] Narayanan D., Phanishayee A., Shi K., et al. Memory-Efficient Pipeline-Parallel DNN Training[EB]. arXiv, 2021

[120] Tarnawski J., Phanishayee A., Devanur N., et al. Efficient Algorithms for Device Placement of DNN Graph Operators[A]. Proceedings of the 34th International Conference on Neural Information Processing Systems[C]. Red Hook, NY, USA: Curran Associates Inc., 2020: 15451-15463

[121] Tarnawski J. M., Narayanan D., Phanishayee A. Piper: Multidimensional

Planner for DNN Parallelization[A]. Advances in Neural Information Process ing Systems: Vol. 34[C]. Curran Associates, Inc., 2021: 24829-24840

[122] Wang H., Li C., Tachon T., et al. Efficient and Systematic Partitioning o f Large and Deep Neural Networks for Parallelization[A]. Euro-Par 2021: P arallel Processing: 27th International Conference on Parallel and Distributed Computing, Lisbon, Portugal, September 1–3, 2021, Proceedings[C]. Berlin, Heidelberg: Springer-Verlag, 2021: 201-216

[123] Elango V. Pase: Parallelization Strategies for Efficient DNN Training[A]. 2021 IEEE International Parallel and Distributed Processing Symposium (IP DPS)[C]. 2021: 1025-1034

[124] Song L., Chen F., Zhuo Y., et al. AccPar: Tensor Partitioning for Hetero geneous Deep Learning Accelerators[A]. 2020 IEEE International Symposiu m on High Performance Computer Architecture (HPCA)[C]. 2020: 342-355

[125] Lin Z., Miao Y., Zhang Q., et al. nnScaler: Constraint-Guided Parallelizat ion Plan Generation for Deep Learning Training[A]. 18th USENIX Symposi um on Operating Systems Design and Implementation[C]. 2024

[126] Addanki R., Venkatakrishnan S. B., Gupta S., et al. Placeto: Learning Ge neralizable Device Placement Algorithms for Distributed Machine Learning [M]. Proceedings of the 33rd International Conference on Neural Informatio n Processing Systems. Red Hook, NY, USA: Curran Associates Inc., 2019: 3981-3991

[127] Zhou Y., Roy S., Abdolrashidi A., et al. GDP: Generalized Device Place ment for Dataflow Graphs[EB/OL]. https://arxiv.org/abs/1910.01578v1, 2019-09-28/2024-08-10

[128] Paliwal A., Gimeno F., Nair V., et al. Reinforced Genetic Algorithm Lea rning for Optimizing Computation Graphs[EB]. arXiv, 2020

[129] Liu J., Wu Z., Feng D., et al. HeterPS: Distributed Deep Learning with Reinforcement Learning Based Scheduling in Heterogeneous Environments[J]. Future Gener. Comput. Syst., 2023,148(C): 106-117

[130] Wang S., Rong Y., Fan S., et al. Auto-MAP: A DQN Framework for Ex ploring Distributed Execution Plans for DNN Workloads[EB/OL]. https://arxi v.org/abs/2007.04069v1, 2020-07-08/2024-08-10

[131] Zhang S., Yi X., Diao L., et al. Expediting Distributed DNN Training W ith Device Topology-Aware Graph Deployment[J]. IEEE Transactions on Par

allel and Distributed Systems, 2023,34(4): 1281-1293